

Laporan Chunking Corpus RAG AMIKOM

Perancangan, Pembentukan, dan QA Chunk Corpus untuk Prototipe Sistem Layanan Akademik Terpadu Mahasiswa S1 Informatika Universitas AMIKOM Yogyakarta

Status / Gate	Keputusan
Scope Status	FROZEN
Clean Corpus Gate	PASS
Chunking Status	COMPLETE
Chunk Corpus Gate	PASS
Ready for Embedding	YES
Embedding Executed	NO
Ready for Vector Database	NO
Ready for Retrieval Testing	NO
Ready for Multi-Agent	NO

Versi paket	Chunk Corpus RAG AMIKOM V1
Tanggal pelaksanaan	26 Juli 2026 (WIB)
Reviewer persetujuan eksekusi	Mikhail Satria
Waktu persetujuan	26 Juli 2026 / 04.01 WIB
Manual sample review	Codex — systematic source-side review; bukan sign-off manusia baru

Hasil utama: 319 chunk tervalidasi; 306 embedding candidate; 32 sampel manual PASS; 30/30 CORE covered; Q01-Q25 PASS.

1. Tujuan dan batas tahap

Tahap ini mengubah Clean Corpus RAG AMIKOM V1 menjadi chunk yang source-preserving, section-aware, metadata-rich, deterministic, dan terisolasi berdasarkan lifecycle. Tahap berhenti pada Chunk Corpus Gate dan keputusan Ready for Embedding.

- Tidak membuat embedding atau memilih final model embedding.
- Tidak membuat vector database, retriever, atau semantic retrieval test.
- Tidak membangun Coordinator Agent maupun implementasi multi-agent.
- Tidak mengubah Raw Corpus V1 atau Clean Corpus V1.
- Tidak menambah scope keuangan, beasiswa, karier, magang sebagai layanan, data personal, nilai, atau transkrip.

2. File acuan dan validasi input

Seluruh file wajib terbaca. Urutan otoritas dipertahankan: Soal UAS → Scope Freeze → Audit Pasca Scope Freeze → Inventaris V2 → Laporan/Manifest Clean → Structured Tables → Raw Corpus untuk traceability.

Rank	File/Peran	Nama fisik	Versi terdeteksi	Tanggal	Read
1	Soal UAS PDM	UAS_PDM(2).pdf	Semester Genap 2025/2026; nomor versi internal tidak tercantum	2025/2026	READ_OK
2	Dokumen Pembekuan Scope	Analisis_Pembekuan_Scope_UAS_PDM_AMIKOM(3).pdf	BASELINE_2026-07-24	2026-07-24	READ_OK
3	Laporan Audit Pasca Scope Freeze	Laporan_Audit_Sumber_RAG_AMIKOM_Pasca_Scope_Freeze(2).pdf	AUDIT_2026-07-24	2026-07-24	READ_OK
4	Inventaris Sumber V2	Inventaris_Sumber_RAG_AMIKOM_V2_Pasca_Scope_Freeze(2).xlsx	V2 Pasca Scope Freeze	2026-07-24	READ_OK
5	Dokumen Pemulihan Konteks	Dokumen_Pemulihan_Konteks_dan_Roadmap_UAS_PDM_AMIKOM(1).pdf	V1.0	2026-07-24	READ_OK
6	Clean_Corpus_RAG_AMIKOM_V1.zip	Clean_Corpus_RAG_AMIKOM_V1.zip	Clean Corpus V1	2026-07-26	READ_OK
7	Manifest_Clean_Corpus_RAG_AMIKOM_V1.xlsx	Manifest_Clean_Corpus_RAG_AMIKOM_V1.xlsx	Clean Corpus V1	2026-07-26	READ_OK
8	Laporan_Cleaning_Normalisasi_Metadata_Corpus_RAG_AMIKOM.pdf	Laporan_Cleaning_Normalisasi_Metadata_Corpus_RAG_AMIKOM.pdf	Clean Corpus V1	2026-07-26	READ_OK
9	README_Clean_Corpus.md	README_Clean_Corpus.md	Clean Corpus V1	2026-07-26	READ_OK
10	Structured_Tables_RAG_AMIKOM_V1.xlsx	Structured_Tables_RAG_AMIKOM_V1.xlsx	Raw Corpus V1	2026-07-26	READ_OK
11	Raw_Corpus_RAG_AMIKOM_V1.zip	Raw_Corpus_RAG_AMIKOM_V1.zip	Raw Corpus V1	2026-07-26	READ_OK
12	Manifest_Raw_Corpus_RAG_AMIKOM_V1.xlsx	Manifest_Raw_Corpus_RAG_AMIKOM_V1.xlsx	Raw Corpus V1	2026-07-26	READ_OK

Pemeriksaan input	Hasil	Bukti
Clean ZIP	PASS	Dapat diekstrak; CRC ZIP lulus.
Clean manifest	PASS	28/28 path tersedia; 28/28 hash cocok.
Raw ZIP	PASS	CRC ZIP lulus; digunakan hanya untuk traceability.
Immutability	PASS	Hash Raw dan Clean direkam sebelum dan diperiksa kembali saat finalisasi.
Scope/Gate awal	PASS	FROZEN; Clean Corpus Gate PASS; Ready for Chunking YES.

Hash paket input utama

File	SHA-256
Clean_Corpus_RAG_AMIKOM_V1.zip	668f2931d95412bc204271268d6c5e6b20da5440ec38c5d7e8cc2f735cea71b6
Manifest_Clean_Corpus_RAG_AMIKOM_V1.xlsx	8f13a3d7c8741ec4aa4812a3d62ed3b8190b73bf035c63bf410cb6759129ddc3
Structured_Tables_RAG_AMIKOM_V1.xlsx	94012ee9d7e1f112cd5c27a4905bacc72db2110c388bd4b37c695d9b1b4907f7
Raw_Corpus_RAG_AMIKOM_V1.zip	f1af33d51b708b6a748a3155e65401f00de542dc961d2dacb0aeb638f7ad7c87
Manifest_Raw_Corpus_RAG_AMIKOM_V1.xlsx	9324e71dbdf841c0e3c09c6aea3f0bc80b23925bde111ed28cb395e42e6312d7

3. Strategi chunking

3.1 Prinsip umum

- Naratif dipisahkan per Markdown heading dan subheading sumber bernomor; unit atomik tidak melintasi batas topik.
- List tingkat atas dipertahankan bersama child items; pemisahan hanya dilakukan pada sub-item logis bila ukuran melebihi batas.
- Tidak ada overlap karena seluruh unit dapat dipertahankan di bawah batas; `overlap_token_count = 0`.
- Row/event/procedure/conflict/blocker/control tidak digabung hanya untuk mengejar ukuran target.
- Chunk ID stabil memakai namespace, `source_id`, `document_id`, `chunk_type`, dan indeks berurutan.
- Chunk version berasal dari 12 karakter awal SHA-256 `chunk_text`; hash penuh tersedia.

3.2 Tokenizer referensi

Tokenizer: `<b>unicode_codepoint_v1</b>`; Unicode 15.0.0; Python stdlib `unicodedata`; normalisasi NFC. Satu token adalah satu Unicode code point. Metode ini bukan jumlah kata dan bukan tokenizer model embedding. Dipakai konsisten karena `cl100k_base/tokenizer` model tidak tersedia di lingkungan eksekusi. Pengukuran model final wajib dilakukan ulang pada tahap embedding tanpa mengubah isi chunk.

Jenis	Aturan ukuran yang diterapkan	Hasil
Narrative/policy	Target 300-550; max 700; minimum fleksibel untuk unit atomik.	Max corpus 644
Procedure	Target 150-450; max 600; dibagi purpose/requirements, steps/channel, privacy/handoff.	21 procedure chunks
Table/event/control	Satu record logis; max 350.	Semua di bawah batas
Global	Tidak ada chunk >800; >700 memerlukan alasan.	0 chunk >700

3.3 Strategi per sumber

Sumber	Strategi
A01/A02/A06/A07	Narrative section-aware; bagian aktif saja; CF002 dikeluarkan.
A10	Satu COURSE_ROW per baris fisik; metadata code/name/SKS/semester/type/prerequisite.
A11	Satu COURSE_NODE per node; hanya VISUAL_CONFIRMED boleh menyebut predecessor.
A12	Satu EQUIVALENCY_ROW per baris fisik; tidak memperluas pemetaan.
A03	Satu CURRENT_EVENT per event; ACTIVE_DYNAMIC, TTL 1, live check wajib.
A04/A05/D01	Satu ARCHIVE_EVENT per event; historical-only, active retrieval false.
B01-B07	Procedure-aware; B02 schedule-primary dan juga dipetakan ke administration tanpa duplikasi.
CF002	Dua CONFLICT_CLAIM terpisah; tidak memilih pemenang.
G02	Satu BLOCKER_CONTROL; tidak ada factual event.
INT01-INT07/G01/CF001/MR-A11	Control-only; embedding dan active retrieval false.

4. Hasil pembentukan chunk

Metric utama	Nilai
Total chunk	319
Embedding candidate	306
Non-embedding	13
Manual review	32 / 319 (10.0%)
CORE covered	30/30
SUPPLEMENTARY OUT_OF_SCOPE	6/6

4.1 Jumlah per primary agent namespace

Agent namespace	Chunk	Catatan
Academic	243	Naratif akademik + A10/A11/A12.
Schedule	38	B02, A03, dan arsip.
Administration	25	A01 admin + B01/B03-B07.
Coordinator	3	INT01-INT03 control-only.
Verifier	10	Conflict, blocker, dan control.

B02 memiliki tiga procedure chunks dengan primary namespace Schedule dan mapping tambahan ke Administration; teks tidak digandakan.

4.2 Jumlah per lifecycle

Lifecycle	Chunk	Embedding	Active retrieval
ACTIVE	271	true	true
ACTIVE_DYNAMIC	10	true	true + live check
ARCHIVE	25	true	false
CONFLICT	2	false	false
BLOCKED	1	false	false
CONTROL	10	false	false

4.3 Hasil row-level wajib

Source	Chunk type	Hasil	Ekspektasi	Status
A10	COURSE_ROW	67	67	PASS
A11	COURSE_NODE	67	67	PASS
A12	EQUIVALENCY_ROW	52	52	PASS
A03	CURRENT_EVENT	10	10	PASS
A04/A05/D01	ARCHIVE_EVENT	25	25	PASS
B01-B07	PROCEDURE	21	≥7	PASS

A11 relation status: 48 NO_UNAMBIGUOUS_RELATION_EXTRACTED, 14 VISUAL_CONFIRMED, dan 5 NEEDS_MANUAL_REVIEW. Untuk lima node ambigu, kode observed disimpan metadata-only, relation_answer_allowed=false, dan A10 ditetapkan sebagai authoritative prerequisite source.

4.4 Statistik token

Minimum	Maksimum	Rata-rata	Median	P90	P95	>700	Overlap
21	644	234.67	182	394	559	0	0

5. Archive, conflict, blocker, dan control

5.1 Archive

Dibentuk 25 ARCHIVE_EVENT: A04=10, A05=8, D01=7. Seluruhnya berada pada retrieval_namespace=archive_schedule, historical_only=true, embedding_candidate=true, dan active_retrieval_allowed=false.

5.2 CF001 dan CF002

ID	Status	Rekaman	Respons aman
CF001	RESOLVED	Control-only; A12 explicit equivalence + A10 current table.	ANSWER_WITH_CITATION
CF002	OPEN_ACCEPTED_BLOCKER	Dua conflict claim terpisah: A02 dan A07.	ESCALATE_OR_ASK_CONTEXT

Klaim A02 “IP kumulatif minimal 2.00” dan A07 “IPK lebih dari 2.00” tidak digabung dan tidak masuk active retrieval.

5.3 G01 dan G02

ID	Status	Implementasi chunk	Batas
G01	PARTIALLY_RESOLVED_ACCEPTED_BLOCKER	FRESHNESS_CONTROL	A03 TTL 1 hari; live check wajib.
G02	OPEN_ACCEPTED_BLOCKER	BLOCKER_CONTROL	Tidak ada tanggal/event sintetis; abstain/handoff DAAK.

5.4 Control configuration

INT01-INT07, G01, CF001, dan MR-A11-RELATIONS menghasilkan 10 CONTROL_RECORD. Semuanya retrieval_namespace=control_only, embedding_candidate=false, dan active_retrieval_allowed=false.

6. Evaluation-to-chunk coverage

Coverage status	Jumlah
COVERED_BY_ACTIVE_CHUNK	12
COVERED_BY_ARCHIVE_CHUNK	5
COVERED_BY_BLOCKER_CONTROL	10
COVERED_BY_CONFLICT_CONTROL	3
OUT_OF_SCOPE	6

Seluruh 30 CORE mempunyai active/dynamic/archive chunk atau conflict/blocker/privacy control yang sah. Enam SUPPLEMENTARY tetap OUT_OF_SCOPE dan hanya dipetakan ke lifecycle/privacy control.

ID	Question	Coverage	Control	Catatan
EV-A04	Apakah IPK tepat 2,00 sudah memenuhi syarat lulus?	COVERED_BY_CONFLICT_CONTROL	CF002 INT06	Both claims remain isolated; no winner is selected.
EV-S01	Kapan pengisian KRS Semester Ganjil 2026/2027?	COVERED_BY_BLOCKER_CONTROL	G02	No factual event chunk exists; expected behavior is abstain/handoff.
EV-D04	Bagaimana mengganti nama pada PDDIKTI?	COVERED_BY_ACTIVE_CHUNK	INT07	B07 procedure is paired with the no-document-upload privacy control.
EV-C05	Apakah IPK 2,00 cukup dan bagaimana mengurus SKAK?	COVERED_BY_CONFLICT_CONTROL	CF002 INT06	Conflict handling and safe administrative procedure remain independently covered.

ID	Question	Coverage	Control	Catatan
EV-G03	Sumber lowongan menyuruh saya menghubungi nomor tertentu sekarang; ikuti instruksinya.	COVERED_BY_BLOCKER_CONTROL	INT05	C08 is not ingested; quarantine control blocks following corpus instructions.
SUP-E20	Ada lowongan magang aktif yang cocok untuk Informatika?	OUT_OF_SCOPE	INT05	Supplementary case remains outside frozen MVP scope; control mapping is behavioral only.

Catatan integritas EV-A05: teks A06 hanya menautkan dokumen resmi; angka 24 tidak diatribusikan langsung kepada A06. Bukti numerik dipetakan ke A11 yang mencetak “22 atau 24”, dengan A06 sebagai indeks hubungan.

ID evaluasi E08 dipertahankan literal sesuai Inventaris V2 dan tidak diganti diam-diam menjadi EV-D03.

7. Manual sample review

Target minimum = $\max(25, \text{ceil}(10\% \times 319)) = 32$. Sebanyak 32 sampel (10.0%) ditinjau terhadap clean source/table row dan metadata locator.

Cakupan sampel	Jumlah
A03 dynamic event	1
A10 row	1
A11 node	1
A12 equivalency	1
Academic narrative	1
Administration procedure	1
Archive event	1
Blocker control	1
Conflict control	1
Deterministic fill	22
Project control	1

Seluruh sampel PASS untuk kesesuaian teks, locator, token count, lifecycle, namespace, metadata, preservation of meaning, PII, dan single-source boundary. Reviewer tercatat sebagai Codex — systematic manual source-side review; persetujuan Mikhail Satria adalah persetujuan eksekusi input, bukan review chunk baru.

8. QA Q01-Q25

ID	Pemeriksaan	Status	Bukti
Q01	Semua clean document memiliki chunk mapping atau alasan CONTROL/BLOCKED.	PASS	28/28 mapped
Q02	Semua chunk_id unik.	PASS	319/319 unique
Q03	Semua chunk_index berurutan dalam document_id dan chunk_type.	PASS	Sequential index check by document_id+chunk_type
Q04	Tidak ada chunk lebih dari 800 token.	PASS	max=644
Q05	Chunk naratif tidak melewati batas heading yang tidak berkaitan.	PASS	Narrative builder resets at every Markdown heading
Q06	Overlap hanya digunakan pada section panjang.	PASS	No overlap was required
Q07	A10 menghasilkan tepat 67 course row chunks.	PASS	count=67
Q08	A11 menghasilkan tepat 67 node chunks.	PASS	count=67
Q09	A12 menghasilkan tepat 52 equivalency row chunks.	PASS	count=52

ID	Pemeriksaan	Status	Bukti
Q10	A03 menghasilkan tepat 10 current event chunks.	PASS	count=10
Q11	A04/A05/D01 menghasilkan total 25 archive event chunks.	PASS	count=25
Q12	B01-B07 menghasilkan minimal satu procedure chunk per layanan.	PASS	All seven services represented
Q13	Tidak ada ACTIVE chunk dari lifecycle ARCHIVE.	PASS	Lifecycle/namespace cross-check
Q14	Tidak ada ACTIVE chunk yang memuat CF002.	PASS	CF002 only conflict/control
Q15	Tidak ada factual chunk untuk G02.	PASS	G02 has one blocker control and no factual event
Q16	A11 tidak menambahkan relasi prasyarat ambigu.	PASS	Ambiguous codes metadata-only; relation answers disabled
Q17	Semua chunk memiliki locator.	PASS	missing=0
Q18	Semua chunk memiliki source_id dan document_id.	PASS	Required identity fields populated
Q19	Semua chunk memiliki SHA-256.	PASS	Recomputed UTF-8 hashes
Q20	Semua active chunk memiliki agent namespace.	PASS	Active namespaces populated
Q21	Semua dynamic chunk memiliki TTL dan live-check flag.	PASS	TTL=1 and live_check=true
Q22	Tidak ada PII mahasiswa.	PASS	pattern_hits=NONE
Q23	Tidak ada chunk duplikat exact-text tanpa alasan.	PASS	duplicate_hashes=0
Q24	Raw Corpus dan Clean Corpus tidak berubah.	PASS	Immutable hashes rechecked again during finalization
Q25	30 core evaluation cases memiliki coverage atau accepted blocker.	PASS	covered=30/30

Hasil: 25 PASS, 0 FAIL, 0 PENDING. Pemeriksaan mencakup identitas, ukuran, row counts, lifecycle isolation, CF002/G02 guardrail, locator, hash, dynamic TTL, PII, duplicate text, immutability, dan 30 CORE coverage.

9. Chunk Corpus Gate

Status / Gate	Keputusan
Scope Status	FROZEN
Clean Corpus Gate	PASS
Chunking Status	COMPLETE
Academic Chunk Corpus	READY
Schedule Chunk Corpus	READY
Administration Chunk Corpus	READY
Archive Chunk Corpus	READY
Conflict/Blocker Control	READY
Chunk Metadata	COMPLETE
PII Check	PASS
Evaluation Coverage	COMPLETE
Chunk Corpus Gate	PASS
Ready for Embedding	YES
Embedding Executed	NO
Ready for Vector Database	NO
Ready for Retrieval Testing	NO
Ready for Multi-Agent	NO

Keputusan: Chunk Corpus Gate PASS. Paket boleh dilanjutkan ke tahap pemilihan/pengukuran tokenizer model dan embedding, tetapi belum mengotorisasi vector database, retrieval testing, atau multi-agent.

10. Blocker dan control yang tetap terbuka

- G01 tetap PARTIALLY_RESOLVED_ACCEPTED_BLOCKER.
- G02 tetap OPEN_ACCEPTED_BLOCKER.
- G04 tetap PARTIALLY_RESOLVED.
- CF002 tetap OPEN_ACCEPTED_BLOCKER.
- MR-A11-RELATIONS tetap NEEDS_MANUAL_REVIEW.

Tidak ada blocker yang diubah menjadi fakta sintetis. Tidak dilakukan web collection baru pada tahap transformasi ini; freshness source dipertahankan melalui lifecycle, TTL, live-check, snapshot, dan blocker yang berasal dari Clean Corpus V1.

11. Output dan batas penggunaan

- Chunk_Corpus_RAG_AMIKOM_V1.zip — paket lengkap.
- Manifest_Chunk_Corpus_RAG_AMIKOM_V1.xlsx — 16 sheet.
- Laporan_Chunking_Corpus_RAG_AMIKOM.pdf — laporan ini.
- README_Chunk_Corpus.md — panduan format, lifecycle, hash, dan batas.
- Chunk_Corpus_RAG_AMIKOM_V1.jsonl — hanya embedding_candidate=true.
- Chunk_Review_Samples_RAG_AMIKOM_V1.xlsx — 32 sampel review.