

# Laporan Baseline RAG dan Retrieval Testing

Corpus RAG AMIKOM — Paket Baseline\_RAG\_Retrieval\_Test\_RAG\_AMIKOM\_V1

Disusun: 2026-07-27 14:16:56 WIB | Scope Status: FROZEN | Vector Database Gate: PASS

## Ringkasan Eksekutif

Tahap ini membangun retriever baseline di atas Vector Database RAG AMIKOM V1 (FAISS IndexIDMap2(IndexFlatIP) 306 vector, dimensi 384, ditambah metadata SQLite 306 record), menjalankan lapisan kontrol dan filter metadata sebelum ranking, menguji 30 kasus CORE dan 6 kasus SUPPLEMENTARY pada k = 1, 3, 5, 10, menetapkan baseline top-k, lalu menjalankan satu baseline RAG generator tunggal beserta evaluasi accuracy, effectiveness, efficiency, explainability, dan hallucination. Seluruh artefak tahap sebelumnya diverifikasi SHA-256 dan tidak dimodifikasi.

**BATASAN UTAMA:** query encoder yang dimandatkan (Xenova/multilingual-e5-small revisi 761b726dd34fb83930e26aab4e9ac3899aa1fa78) TIDAK dapat dijalankan karena huggingface.co diblokir oleh proxy lingkungan eksekusi (CONNECT 403) dan artefak model tidak dibundel pada paket input mana pun. Akibatnya tidak ada query vector yang dihasilkan dan FAISS search tidak dijalankan untuk 36 query evaluasi. Atas persetujuan eksplisit pemilik pekerjaan, tahap ini dilanjutkan memakai retriever pengganti berbasis leksikal BM25 Okapi (FALLBACK\_LEXICAL\_BM25\_V1) sehingga lapisan kontrol, filter, metrik, dan generasi tetap teruji ujung ke ujung. Konsekuensinya angka Hit@k, Recall@k, Precision@k, dan MRR pada laporan ini TIDAK mewakili performa vector search E5 dan baseline top-k bersifat sementara.

## Status Akhir

| Item                                 | Nilai                                                                                                   |
|--------------------------------------|---------------------------------------------------------------------------------------------------------|
| Scope Status                         | FROZEN                                                                                                  |
| Vector Database Gate                 | PASS (diverifikasi ulang: hash, ntotal 306, dim 384)                                                    |
| Retrieval Testing                    | PARTIALLY_COMPLETE                                                                                      |
| Baseline Top-k                       | 5 (sementara, backend leksikal)                                                                         |
| Retrieval Metrics                    | Hit@1 0.65   Hit@3 0.8   Hit@5 0.8   Hit@10 0.95   Recall@5 0.7275   Precision@5 0.3975   MRR@10 0.7439 |
| Control Accuracy                     | 1.0 (36/36)                                                                                             |
| Archive Leakage                      | 0                                                                                                       |
| Baseline RAG                         | COMPLETE                                                                                                |
| Retrieval Gate                       | CONDITIONAL_PASS                                                                                        |
| Baseline RAG Gate                    | CONDITIONAL_PASS                                                                                        |
| Ready for Multi-Agent Implementation | NO                                                                                                      |
| Multi-Agent Executed                 | NO                                                                                                      |

## 1. Validasi Input dan Database

Enam artefak input diverifikasi ulang dengan SHA-256 terhadap final\_package\_validation.json dan seluruhnya identik (PASS). FAISS terbaca dengan ntotal 306 dan dimensi 384; SQLite memuat 306 record dengan vector\_index 0-305. Hash file faiss.index dan metadata.sqlite identik dengan reload\_test.json tahap sebelumnya, sehingga artefak terbukti tidak berubah. Database dibuka read-only (SQLite URI mode=ro).

Uji fungsional FAISS dilakukan tanpa query vector: vektor pada index 0 direkonstruksi lalu dicari kembali. Hasilnya self-match pada index 0 dengan skor 1.0 dan norm 1.0, membuktikan index berfungsi dan ternormalisasi kosinus. Uji ini TIDAK membuktikan retrieval sisi query.

## 2. Query Embedding

| Aspek                      | Spesifikasi wajib                        | Status eksekusi                                                 |
|----------------------------|------------------------------------------|-----------------------------------------------------------------|
| Model                      | Xenova/multilingual-e5-small             | NOT_EXECUTED                                                    |
| Revision                   | 761b726dd34fb83930e26aab4e9ac3899aa1fa78 | NOT_EXECUTED                                                    |
| Tokenizer                  | XLMLRobertaTokenizer resmi model         | NOT_EXECUTED                                                    |
| Prefix query               | query: [pertanyaan]                      | Dibentuk untuk 36 query dan disimpan pada field formatted_query |
| Prefix passage             | tidak boleh dipakai untuk pertanyaan     | Dipatuhi                                                        |
| Pooling                    | mean                                     | NOT_EXECUTED                                                    |
| Normalisasi                | L2                                       | NOT_EXECUTED                                                    |
| Dimensi / dtype            | 384 / float32                            | Tidak ada vector dihasilkan                                     |
| Validasi NaN/Inf/zero/norm | wajib                                    | Tidak dapat dijalankan                                          |

## 3. Control dan Routing Sebelum Retrieval

Record CONTROL (10), CONFLICT (2), dan BLOCKED (1) dimuat terpisah dari Chunk Corpus dan tidak pernah diperlakukan sebagai vector knowledge — ketiganya memang tidak diindeks (dikonfirmasi FV11). Lapisan kontrol dijalankan sebelum filter dan sebelum ranking, dengan urutan prioritas: privacy/PII (INT07), out-of-scope (beasiswa, keuangan, karier, magang), sumber karantina (INT05), archive-sebagai-current (INT05), konflik terbuka CF002 (INT06), rute temporal G02/G01, penyetaraan CF001, dan relasi ambigu MR-A11-RELATIONS. Ketika G02 aktif, namespace jadwal dibuang dari himpunan kandidat sehingga tidak ada tanggal yang dapat bocor ke context.

| ID     | control_triggered               | mode diharapkan | mode diputuskan | hasil | retrieval_status      |
|--------|---------------------------------|-----------------|-----------------|-------|-----------------------|
| EV-A02 | CF001                           | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-A04 | CF002 INT06                     | ESCALATE        | ESCALATE        | OK    | EXECUTED              |
| EV-A06 | CF001                           | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-S01 | G02 G01                         | ABSTAIN         | ABSTAIN         | OK    | CONTROL_SHORT_CIRCUIT |
| EV-S02 | G02 INT05 G01                   | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-S03 | INT05 G01                       | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-S04 | INT05 G01                       | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-S05 | G02 G01                         | ASK_CONTEXT     | ASK_CONTEXT     | OK    | EXECUTED              |
| EV-S06 | INT07                           | ESCALATE        | ESCALATE        | OK    | CONTROL_SHORT_CIRCUIT |
| EV-D06 | G01                             | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-C01 | G02 G01                         | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-C02 | CF001 G01                       | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-C03 | G02 G01                         | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-C04 | G02 G01                         | ASK_CONTEXT     | ASK_CONTEXT     | OK    | EXECUTED              |
| EV-C05 | CF002 INT06                     | ESCALATE        | ESCALATE        | OK    | EXECUTED              |
| EV-C06 | INT05 G01                       | ANSWER          | ANSWER          | OK    | EXECUTED              |
| EV-G01 | INT07                           | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| EV-G02 | INT07                           | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| EV-G03 | INT07 OUT_OF_SCOPE:KARIER INT05 | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |

| ID      | control_triggered               | mode diharapkan | mode diputuskan | hasil | retrieval_status      |
|---------|---------------------------------|-----------------|-----------------|-------|-----------------------|
| EV-G04  | INT05                           | ABSTAIN         | ABSTAIN         | OK    | CONTROL_SHORT_CIRCUIT |
| EV-G05  | CF002 INT06                     | ESCALATE        | ESCALATE        | OK    | EXECUTED              |
| EV-G06  | INT07 OUT_OF_SCOPE:BEASISWA     | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| SUP-E03 | INT07 OUT_OF_SCOPE:KEUANGAN     | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| SUP-E14 | INT07 OUT_OF_SCOPE:MAGANG       | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| SUP-E15 | INT07 OUT_OF_SCOPE:MAGANG       | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| SUP-E16 | INT07 OUT_OF_SCOPE:BEASISWA     | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| SUP-E17 | INT07 OUT_OF_SCOPE:BEASISWA     | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |
| SUP-E20 | INT07 OUT_OF_SCOPE:KARIER INT05 | REFUSE          | REFUSE          | OK    | CONTROL_SHORT_CIRCUIT |

## 4. Metadata Filter Sebelum Ranking

Kandidat `vector_index` ditentukan lebih dulu melalui SQLite, baru skor dihitung pada kandidat tersebut. Tidak ada global top-k yang kemudian dibuang. Predikat `current`: `active_retrieval_allowed=1 AND historical_only=0 AND retrieval_namespace IN (namespace aktif hasil routing)`. Predikat `historis`: `historical_only=1 AND lifecycle_status='ARCHIVE' AND retrieval_namespace='archive_schedule'`. Mode `MIXED` dipakai untuk pertanyaan multi-intent yang menggabungkan sub-intent historis dan prosedural `current`.

Hasil: `namespace/filter` accuracy 1.00 pada 36 query, isolasi historis 1.00 pada 3 query archive, dan archive leakage 0 pada seluruh query `current` bahkan pada `k=10`. Sepuluh record `ACTIVE_DYNAMIC` (A03, ttl 1 hari, snapshot 2026-07-24) dinilai kedaluwarsa pada waktu eksekusi 2026-07-27 sehingga diberi `response_mode LIVE_CHECK_OR_ABSTAIN`.

## 5. Hasil Retrieval dan Perbandingan Top-k

Metrik retrieval dihitung pada subset ber-skor: 20 query yang memang menuntut retrieval faktual (`expected_response_mode ANSWER` atau `ASK_CONTEXT`) dan memiliki minimal satu gold chunk di dalam database. Enam belas query sisanya adalah kasus kontrol (`ABSTAIN/ESCALATE/REFUSE`) yang gold chunk-nya berupa record `CONTROL/CONFLICT/BLOCKED` di luar vector database; kasus tersebut dinilai melalui `control decision accuracy`, bukan `Hit@k`.

| k  | Hit@k | Recall@k | Precision@k | MRR@k  | Source acc | Chunk tak relevan | Token context (est.) | Latency P95 (ms) | Keputusan |
|----|-------|----------|-------------|--------|------------|-------------------|----------------------|------------------|-----------|
| 1  | 0.65  | 0.3225   | 0.65        | 0.65   | 0.8        | 0.35              | 68.5                 | 1.618            |           |
| 3  | 0.8   | 0.6467   | 0.55        | 0.725  | 0.95       | 1.35              | 208.9                | 1.453            |           |
| 5  | 0.8   | 0.7275   | 0.3975      | 0.725  | 0.95       | 3.0               | 344.6                | 1.291            | DIPILIH   |
| 10 | 0.95  | 0.9125   | 0.3125      | 0.7439 | 0.95       | 6.4               | 616.4                | 1.294            |           |

Baseline top-k ditetapkan 5. `Hit@5` sama dengan `Hit@3` (0.80) tetapi `Recall@5` lebih tinggi (0.73 vs 0.65) karena banyak gold prosedural terdiri dari 3-6 chunk (B03, B04, B05, B06, B07, B01+B02). Menaikkan `k` ke 10 memang mengangkat `Hit` ke 0.95 dan `Recall` ke 0.91, tetapi menambah rata-rata 6.4 chunk tidak relevan per query (context 616 token) sehingga memperbesar risiko `unsupported generation`, sementara `MRR` hampir tidak berubah (0.725 ke 0.744). `Latency` tidak menjadi pembeda pada backend leksikal. Nilai ini dicatat sebagai `baseline_top_k`, bukan final production top-k, dan wajib ditinjau ulang setelah encoder E5 tersedia serta pada tahap multi-agent evaluation.

## 6. Baseline RAG

Pipeline yang dijalankan: query → control check → metadata filter → (query embedding: NOT\_EXECUTED) → retrieval → context assembly → satu generator LLM → jawaban + citation. Generator adalah satu model tunggal (claude-opus-5) tanpa coordinator, verifier, atau agen lain. Context memuat chunk\_text, title, source\_id, locator, lifecycle, dan freshness; control directive disertakan terpisah sebagai dasar keputusan mode, bukan sebagai fakta.

| Dimensi        | Hasil                                                                                                                                                                                                                |
|----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Accuracy       | response mode 36/36 (1.0); factual PASS 0.75, PARTIAL 0.25, FAIL 0.0 pada 20 query ber-skor                                                                                                                          |
| Effectiveness  | 15 PASS, 6 PARTIAL, 2 ABSTAIN_CORRECT, 4 HANDOFF_CORRECT, 9 OUT_OF_SCOPE_CORRECT, 0 FAIL                                                                                                                             |
| Efficiency     | retrieval latency mean 0.6124 ms, median 0.4895 ms, P95 1.291 ms; context rata-rata 4.95 chunk / 344.6 token; generation latency NOT_MEASURED                                                                        |
| Explainability | 23 jawaban bersitasi, 13 jawaban jalur kontrol tanpa sitasi (memang tanpa retrieval faktual); seluruh citation dapat ditelusuri ke chunk_id, source_id, dan locator; alasan abstain/handoff tercatat pada 24 jawaban |
| Hallucination  | unsupported claim 0, citation mismatch 0, archive dipakai untuk pertanyaan current 0, fakta sintetis pada blocker/conflict 0, pelanggaran PII 0                                                                      |

## 7. Error Analysis

| ID     | Kategori       | Penyebab                                                                                                                                                                                                                       | Perbaikan disarankan                                                                                                                       |
|--------|----------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| EV-A01 | WRONG_SOURCE   | BM25 memberi skor tertinggi pada chunk A07 bertema 'jalur kelulusan' (kecocokan kata 'kelulusan') sementara chunk A07 yang memuat angka 144 SKS berada di peringkat 10; chunk A02 yang juga memuat 144 sks menang peringkat 2. | Gunakan query encoder E5 yang dimandatkan (semantic), atau tambahkan source_priority tie-break dan field-weighted BM25 pada judul/section. |
| EV-A05 | RETRIEVAL_MISS | Pertanyaan menyebut 'halaman kurikulum'; gold A06 adalah tabel tautan tanpa istilah 'SKS maksimal', sehingga tidak ada sinyal leksikal.                                                                                        | Retriever semantik (E5) wajib; tambahkan alias 'halaman kurikulum' -> source A06 pada routing table.                                       |
| EV-D06 | RETRIEVAL_MISS | Gold memiliki 6 chunk (B01+B02); k=5 hanya memuat sebagian, chunk B01 kalah skor terhadap chunk B02 dan A01.                                                                                                                   | Naikkan k untuk pertanyaan prosedural multi-chunk atau lakukan per-source diversification (max-per-source lalu merge).                     |
| EV-C01 | RETRIEVAL_MISS | Query multi-intent; token schedule ('KRS Ganjil 2026/2027') mengambil porsi besar skor sedangkan sub-intent akademik hanya 3 token.                                                                                            | Dekomposisi sub-query per intent (tugas Coordinator Agent pada tahap multi-agent) dengan k terpisah per sub-intent.                        |
| EV-C05 | ROUTING_ERROR  | Routing menggabungkan namespace akademik+administrasi dalam satu ranking; 271 kandidat akademik mendominasi 25 kandidat administrasi.                                                                                          | Retrieve per namespace lalu merge (round-robin) alih-alih satu ranking gabungan.                                                           |
| EV-C06 | FILTER_ERROR   | Filter MIXED menggabungkan 25 kandidat arsip dan 25 kandidat administrasi dalam satu ranking; token 'agenda/Genap 2025/2026' mendominasi sehingga B05 tergeser.                                                                | Alokasikan kuota k per sub-intent (mis. 3 arsip + 3 administrasi) pada mode MIXED.                                                         |

Tidak ada kategori ARCHIVE\_LEAKAGE, WRONG\_LIFECYCLE, FRESHNESS\_FAILURE, CONTROL\_FAILURE, CITATION\_MISMATCH, UNSUPPORTED\_GENERATION, maupun OUT\_OF\_SCOPE\_FAILURE yang terjadi. Tidak ada corpus atau gold answer yang diubah untuk menaikkan skor.

## 8. QA Registry Q01-Q18

| ID  | Deskripsi                                  | Status  | Evidence                                                                                                                                                                                                 |
|-----|--------------------------------------------|---------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Q01 | Database berhasil dibuka kembali           | PASS    | FAISS ntotal=306 d=384; SQLite vector_records=306; hash faiss.index dan metadata.sqlite identik dengan reload_test.json tahap sebelumnya.                                                                |
| Q02 | Query memakai prefix 'query:'              | PARTIAL | Prefix 'query: ' dibentuk dan disimpan pada field formatted_query untuk 36 query, tetapi tidak pernah masuk ke encoder karena encoder diblokir; prefix 'passage:' tidak pernah dipakai untuk pertanyaan. |
| Q03 | Query vector valid dan dimensi 384         | FAIL    | NOT_EXECUTED. Model Xenova/multilingual-e5-small rev 761b726... tidak dapat diunduh (huggingface.co diblokir proxy 403) sehingga tidak ada query vector yang dihasilkan.                                 |
| Q04 | Filter dilakukan sebelum ranking           | PASS    | candidate_indexes() mengambil vector_index dari SQLite lebih dahulu; skor hanya dihitung pada kandidat tersebut (tidak ada global top-k).                                                                |
| Q05 | Current search mengambil 0 archive         | PASS    | archive_leakage_count = 0 pada seluruh 33 query bermode CURRENT (k=10).                                                                                                                                  |
| Q06 | Historical search hanya memakai archive    | PASS    | 3 query HISTORICAL (EV-S02/S03/S04) 100% mengembalikan lifecycle ARCHIVE.                                                                                                                                |
| Q07 | G02 memicu abstain/handoff                 | PASS    | EV-S01 ABSTAIN; EV-C01/C03 partial abstain + handoff DAAK; tidak ada tanggal Ganjil 2026/2027 yang muncul pada jawaban mana pun.                                                                         |
| Q08 | CF002 memicu conflict response             | PASS    | EV-A04, EV-C05, EV-G05 semuanya ESCALATE dan mengungkap konflik; tidak ada nilai IPK tunggal yang dipilih.                                                                                               |
| Q09 | Dynamic record diperiksa freshness         | PASS    | 10 record ACTIVE_DYNAMIC (A03, ttl=1 hari, snapshot 2026-07-24) dinilai expired pada 2026-07-27 -> response_mode LIVE_CHECK_OR_ABSTAIN.                                                                  |
| Q10 | Seluruh 30 CORE dievaluasi                 | PASS    | 30 baris pada Retrieval_Results_CORE.jsonl dan 30 jawaban baseline.                                                                                                                                      |
| Q11 | Seluruh 6 SUPPLEMENTARY diuji out-of-scope | PASS    | 6 baris SUPPLEMENTARY, semuanya REFUSE + redirect, 0 retrieval faktual.                                                                                                                                  |
| Q12 | Top-k dibandingkan                         | PASS    | k=1,3,5,10 dijalankan penuh untuk 36 query; tabel perbandingan tersedia.                                                                                                                                 |
| Q13 | Metrik retrieval dihitung                  | PASS    | Hit@k, Recall@k, Precision@k, MRR, source/namespace/control accuracy, archive isolation, latency mean/median/P95.                                                                                        |
| Q14 | Baseline RAG menghasilkan citation         | PASS    | 23 jawaban faktual seluruhnya bersitasi chunk yang valid; 13 jawaban kontrol tanpa sitasi karena memang tidak melakukan retrieval faktual.                                                               |
| Q15 | Unsupported claim diperiksa                | PASS    | check_generation.py: 0 token numerik tak-terdukung, 0 citation mismatch, 0 penggunaan ARCHIVE untuk pertanyaan current, 0 kebocoran PII.                                                                 |
| Q16 | Latency tercatat                           | PASS    | control/filter/ranking/total per query per k tersimpan pada JSONL.                                                                                                                                       |
| Q17 | Hasil dapat direproduksi                   | PARTIAL | Pipeline deterministik (BM25 + aturan kontrol) dan dapat diulang byte-identik; tetapi tahap ini TIDAK dapat direproduksi dengan encoder yang dimandatkan sampai model E5 tersedia.                       |
| Q18 | Artefak sebelumnya tidak berubah           | PASS    | SHA-256 keenam artefak input diverifikasi ulang dan identik dengan final_package_validation.json; database dibuka read-only (mode=ro).                                                                   |

## 9. Keputusan Gate

Retrieval Gate: CONDITIONAL\_PASS. Seluruh kriteria fungsional terpenuhi — 30 CORE selesai diuji, isolasi filter/lifecycle berfungsi (namespace accuracy 1.00, isolasi historis 1.00), keputusan kontrol benar 36/36, metrik lengkap, nol archive leakage, dan tidak ada blocker yang berubah menjadi fakta. Kriteria reproduksibilitas dengan encoder yang dimandatkan TIDAK terpenuhi, sehingga gate tidak dapat dinyatakan PASS.

Baseline RAG Gate: CONDITIONAL\_PASS. Jawaban dibangun dari retrieved context, seluruh citation dapat ditelusuri, abstain/escalate/handoff/ask-context berjalan sesuai control registry, pemeriksaan halusinasi menghasilkan nol temuan, dan tidak ada pelanggaran PII. Namun retrieval yang menjadi dasar jawaban bukan vector search yang dimandatkan.

**Ready for Multi-Agent Implementation: NO. Tahap multi-agent tidak boleh dimulai sebelum retrieval berbasis encoder E5 dijalankan ulang dan kedua gate dinaikkan menjadi PASS.**

## 10. Batas Tahap

Paket ini tidak mencakup implementasi multi-agent, Coordinator Agent final, antarmuka aplikasi, deployment, maupun fine-tuning. Corpus, embedding, dan vector database tidak dimodifikasi. Pekerjaan berhenti pada keputusan Ready for Multi-Agent Implementation.

## Lampiran: daftar 36 evaluasi dan grade

| ID      | Set           | Mode diharapkan | Mode diterapkan | Grade                | Error          |
|---------|---------------|-----------------|-----------------|----------------------|----------------|
| EV-A01  | CORE          | ANSWER          | ANSWER          | PARTIAL              | WRONG_SOURCE   |
| EV-A02  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-A03  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-A04  | CORE          | ESCALATE        | ESCALATE        | HANDOFF_CORRECT      | NONE           |
| EV-A05  | CORE          | ANSWER          | ANSWER          | PARTIAL              | RETRIEVAL_MISS |
| EV-A06  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-S01  | CORE          | ABSTAIN         | ABSTAIN         | ABSTAIN_CORRECT      | NONE           |
| EV-S02  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-S03  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-S04  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-S05  | CORE          | ASK_CONTEXT     | ASK_CONTEXT     | PASS                 | NONE           |
| EV-S06  | CORE          | ESCALATE        | ESCALATE        | HANDOFF_CORRECT      | NONE           |
| EV-D01  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-D02  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| E08     | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-D04  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-D05  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-D06  | CORE          | ANSWER          | ANSWER          | PARTIAL              | RETRIEVAL_MISS |
| EV-C01  | CORE          | ANSWER          | ANSWER          | PARTIAL              | RETRIEVAL_MISS |
| EV-C02  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-C03  | CORE          | ANSWER          | ANSWER          | PASS                 | NONE           |
| EV-C04  | CORE          | ASK_CONTEXT     | ASK_CONTEXT     | PASS                 | NONE           |
| EV-C05  | CORE          | ESCALATE        | ESCALATE        | PARTIAL              | RETRIEVAL_MISS |
| EV-C06  | CORE          | ANSWER          | ANSWER          | PARTIAL              | RETRIEVAL_MISS |
| EV-G01  | CORE          | REFUSE          | REFUSE          | HANDOFF_CORRECT      | NONE           |
| EV-G02  | CORE          | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| EV-G03  | CORE          | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| EV-G04  | CORE          | ABSTAIN         | ABSTAIN         | ABSTAIN_CORRECT      | NONE           |
| EV-G05  | CORE          | ESCALATE        | ESCALATE        | HANDOFF_CORRECT      | NONE           |
| EV-G06  | CORE          | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| SUP-E03 | SUPPLEMENTARY | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| SUP-E14 | SUPPLEMENTARY | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| SUP-E15 | SUPPLEMENTARY | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| SUP-E16 | SUPPLEMENTARY | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| SUP-E17 | SUPPLEMENTARY | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |
| SUP-E20 | SUPPLEMENTARY | REFUSE          | REFUSE          | OUT_OF_SCOPE_CORRECT | NONE           |