

PRODUCT REQUIREMENTS DOCUMENT (PRD)

IMPLEMENTASI MULTI-AGENT RAG AMIKOM

Dokumen Eksekusi Terstruktur untuk Google AntigraVity

Versi 1.0

27 Juli 2026

Pemilik: Tim UAS Proyek Data Mining

Status: READY_FOR_IMPLEMENTATION_WITH_RETRIEVAL_BLOCKER

Dokumen ini adalah sumber instruksi utama untuk pembuatan kode. AntigraVity harus bekerja per fase, menghasilkan artefak yang dapat diverifikasi, menjalankan pengujian, dan berhenti apabila gate fase gagal.

Kendali Dokumen

Atribut	Nilai
Judul	PRD Implementasi Multi-Agent RAG AMIKOM untuk Google Antigravity
Versi	1.0
Tanggal	27 Juli 2026
Pemilik	Tim UAS Proyek Data Mining
Status	READY_FOR_IMPLEMENTATION_WITH_RETRIEVAL_BLOCKER
Dokumen terkait	Roadmap Implementasi Multi-Agent; paket Vector Database; paket Baseline RAG dan Retrieval Testing
Sumber kebutuhan	Scope Freeze, corpus/embedding/vector database, control registry, evaluation registry

Daftar Isi

- 1. Ringkasan Produk
- 2. Tujuan Produk
- 3. Keputusan Status Saat Ini
- 4. Pengguna dan Kebutuhan Utama
- 5. Scope
- 6. Arsitektur Target
- 7. Mode Operasi
- 8. Functional Requirements
- 9. Non-Functional Requirements
- 10. Artefak Data Patokan
- 11. Kontrak Data
- 12. API Minimum
- 13. Struktur Repository
- 14. Environment Variables
- 15. Rencana Implementasi untuk Antigravity
- 16. Pengujian
- 17. Risiko dan Mitigasi
- 18. Definition of Done
- 19. Instruksi Eksekusi Antigravity
- 20. Checklist Input Sebelum Eksekusi

1. Ringkasan Produk

Proyek membangun prototipe Sistem Layanan Akademik Terpadu Mahasiswa S1 Informatika Universitas AMIKOM Yogyakarta berbasis Multi-Agent, RAG, embedding, dan vector database. Sistem menjawab pertanyaan akademik, jadwal, dan administrasi menggunakan dokumen resmi yang telah diproses menjadi corpus, chunk, embedding, serta vector database FAISS + SQLite.

Status data saat ini sudah mencakup Raw Corpus, Clean Corpus, Chunk Corpus, 306 embedding dokumen berdimensi 384, dan vector database persisten. Lapisan control, lifecycle, archive, freshness, conflict, blocker, dan PII telah tersedia. Kendala utama adalah query encoder Xenova/multilingual-e5-small belum berhasil dijalankan pada tahap retrieval terakhir. Karena itu implementasi struktur kode dapat dimulai, tetapi status final Multi-Agent tidak boleh dinyatakan siap sebelum retrieval E5 lulus.

2. Tujuan Produk

1. Menyediakan jawaban layanan akademik yang bersumber, dapat ditelusuri, dan aman.
2. Memisahkan tanggung jawab Academic, Schedule, dan Administration Agent.
3. Menggunakan Coordinator untuk routing dan dekomposisi, bukan penciptaan fakta.
4. Menggunakan Verifier/Guardrail deterministik untuk scope, lifecycle, freshness, conflict, blocker, PII, dan citation.
5. Menggunakan vector retrieval E5 sebagai retriever utama dan BM25 hanya sebagai fallback pengembangan.
6. Menghasilkan prototipe yang dapat diuji menggunakan 30 kasus CORE dan 6 kasus SUPPLEMENTARY.

3. Keputusan Status Saat Ini

Komponen	Status	Implikasi
Scope	FROZEN	Tidak menambah domain, agent, atau cohort baru.
Raw/Clean/Chunk Corpus	PASS	Tidak boleh dimodifikasi oleh aplikasi.
Embedding dokumen	PASS	306 vector x 384 dapat digunakan.
Vector Database	PASS	FAISS + SQLite dapat digunakan.
Baseline Retrieval	CONDITIONAL_PASS	Hasil terakhir memakai BM25, bukan query vector E5.
Ready for coding	YES	Scaffold, data layer, control, agent interface, API, dan test dapat dibangun.
Ready for final Multi-Agent claim	NO	Menunggu E5 retrieval dan gate final PASS.

4. Pengguna dan Kebutuhan Utama

4.1 Pengguna utama

Mahasiswa aktif S1 Informatika Universitas AMIKOM Yogyakarta, terutama cohort/Kurikulum 2025.

4.2 User stories

- US-01 Academic: Menanyakan mata kuliah, kode, SKS, konsentrasi, penyetaraan, atau ketentuan kelulusan.
- US-02 Current Schedule: Menanyakan agenda current dan menerima peringatan freshness bila data dinamis kedaluwarsa.
- US-03 Historical Schedule: Menanyakan jadwal periode lampau dan sistem hanya mengambil namespace archive.
- US-04 Administration: Menanyakan prosedur KRS manual, cuti, SKAK, legalisir, KTM, atau perubahan data PDDIKTI.
- US-05 Multi-intent: Menggabungkan pertanyaan lintas domain dan Coordinator memecahnya menjadi sub-query.
- US-06 Conflict: Pertanyaan ambang IPK tepat 2,00 menghasilkan escalation.
- US-07 Blocker: Informasi belum dipublikasikan menghasilkan abstain/handoff.
- US-08 Privacy: Sistem menolak dokumen identitas, credential, nilai, dan data transaksi personal.
- US-09 Explainability: Setiap jawaban faktual menampilkan source_id dan locator.

5. Scope

5.1 In-scope

- Kurikulum 2025, mata kuliah, kode, SKS, konsentrasi, dan penyetaraan.
- Ketentuan akademik dan kelulusan yang tidak berada dalam konflik terbuka.
- Kalender akademik, agenda semester, KRS, perubahan KRS, perkuliahan, ujian, dan cuti terkait jadwal.
- Prosedur KRS manual, cuti, SKAK, legalisir, KTM, dan perubahan data PDDIKTI.
- Current, historical, mixed intent, citation, abstain, escalation, handoff, live-check, dan PII guardrail.

5.2 Out-of-scope

- Keuangan/pembayaran, beasiswa, karier, magang, dan layanan digital umum.
- Program studi atau cohort lain.
- Nilai, transkrip, dashboard personal, status transaksi, formulir terisi, dan dokumen identitas aktual.
- Fine-tuning model dan deployment produksi kampus.

6. Arsitektur Target

User/API

- > Control Precheck
- > Coordinator (intent, temporal mode, decomposition)
- > Academic / Schedule / Administration Specialist
- > Metadata Filter (SQLite)
- > Query Encoder E5
- > FAISS Candidate Retrieval
- > Evidence Merge + Context Assembly
- > Single Generator LLM
- > Deterministic Verifier/Guardrail
- > Final Response + Citation + Freshness/Handoff

6.1 Komponen

- Coordinator Agent: routing, dekomposisi, kuota retrieval, dan merge hasil.
- Academic Agent: namespace active_academic.
- Schedule Agent: active_schedule, active_dynamic_schedule, archive_schedule.
- Administration Agent: active_administration.

- Verifier/Guardrail: aturan deterministik, bukan LLM bebas.
- Generator: satu provider LLM melalui interface dan tidak hardcoded per evaluation_id.

7. Mode Operasi

7.1 DEVELOPMENT_DEGRADED

- Query encoder E5 belum tersedia.
- BM25 boleh digunakan sebagai fallback eksplisit.
- API wajib mengembalikan retrieval_backend=BM25_FALLBACK dan system_readiness=DEGRADED.
- Tidak boleh mengklaim Retrieval Gate PASS atau Ready for Multi-Agent final.

7.2 PRODUCTION_CANDIDATE

- Model E5 resmi berhasil dimuat dari path lokal atau revision yang dipin.
- 36 query menghasilkan vector 384 float32 dengan norm mendekati 1.
- FAISS search dijalankan pada kandidat hasil filter SQLite.
- Retrieval Gate dan Baseline RAG Gate PASS.

8. Functional Requirements

ID	Requirement	Acceptance Criteria
FR-001	Sistem menerima pertanyaan melalui API.	Request tervalidasi, request_id dibuat, query kosong ditolak.
FR-002	Control precheck berjalan sebelum retrieval.	PII, out-of-scope, G02, CF002, dan blocker dapat short-circuit.
FR-003	Coordinator mengklasifikasikan domain dan temporal mode.	Mendukung single/multi-intent; tidak menulis fakta.
FR-004	Coordinator memecah multi-intent menjadi sub-query.	Setiap sub-query memiliki agent, namespace, filter, dan k.
FR-005	Academic Agent mengambil evidence akademik.	Hanya namespace akademik aktif dan precedence sumber.
FR-006	Schedule Agent membedakan current/dynamic/archive.	Current 0 archive; historical hanya archive.
FR-007	Administration Agent menjelaskan prosedur umum.	Tidak memproses transaksi/status personal.
FR-008	Query encoder membuat vector E5.	Prefix query, dimensi 384, float32, L2, tanpa NaN/Inf/zero.
FR-009	Retriever memfilter sebelum ranking.	Kandidat dari SQLite; dilarang global top-k lalu discard.
FR-010	Retriever mencari per namespace/sub-intent.	Hasil di-merge dengan kuota dan diversifikasi.
FR-011	Context assembler menjaga source dan locator.	Evidence memuat chunk_id, source_id, locator, lifecycle, freshness.
FR-012	Generator menjawab hanya dari evidence.	Evidence kurang -> menyatakan tidak ditemukan.
FR-013	Citation formatter konsisten.	Klaim faktual memiliki source_id + locator valid.
FR-014	Verifier memeriksa jawaban akhir.	Scope, PII, lifecycle, freshness, conflict, blocker, citation.
FR-015	Response mode didukung.	ANSWER/ASK_CONTEXT/ABSTAIN/ESCALATE/HANDOFF/REFUSE/LIVE_CHECK.

ID	Requirement	Acceptance Criteria
FR-016	Audit log aman.	Tidak menyimpan PII mentah; latency per tahap tercatat.
FR-017	Health dan readiness endpoint.	Membedakan healthy, degraded, dan ready.
FR-018	Pipeline evaluasi dapat diulang.	30 CORE + 6 SUPPLEMENTARY menghasilkan metrik dan error analysis.
FR-019	BM25 sebagai fallback.	Hanya via konfigurasi dan selalu dilabeli fallback.
FR-020	Artefak immutable tidak ditulis.	Hash input tetap sama.

9. Non-Functional Requirements

ID	Requirement	Target
NFR-001	Reproducibility	Model revision, config, dependency, dan hash tercatat.
NFR-002	Portability	Tidak ada path absolut; path berasal dari env/config.
NFR-003	Security	Secret hanya di .env; PII tidak disimpan dalam log.
NFR-004	Maintainability	Modul terpisah, typed schema, lint, unit test, docstring.
NFR-005	Observability	request_id, latency, backend, agent, source, verification status.
NFR-006	Reliability	Fail-closed pada hash/model/database mismatch atau evidence kosong.
NFR-007	Explainability	Jawaban faktual memiliki citation traceable.
NFR-008	Data integrity	FAISS, SQLite, corpus, embedding, gold dataset read-only.
NFR-009	Testability	Control dan verifier deterministik memiliki unit test.
NFR-010	Graceful degradation	Kegagalan E5/LLM tidak menghasilkan fakta sintetis.

10. Artefak Data Patokan

10.1 Wajib di data/immutable

1. Vector_Database_RAG_AMIKOM_V1.zip
2. Vector_Database_Config_RAG_AMIKOM_V1.json
3. final_package_validation.json
4. Embedding_Config_RAG_AMIKOM_V1.json
5. Chunk_Corpus_RAG_AMIKOM_V1.zip
6. Inventaris_Sumber_RAG_AMIKOM_V2_Pasca_Scope_Freeze.xlsx
7. Baseline_RAG_Retrieval_Test_RAG_AMIKOM_V1.zip
8. Retrieval_Recovery_Prompt.md
9. Roadmap_Implementasi_Multi_Agent_RAG_AMIKOM.pdf

10. Dokumen PRD ini.

10.2 File penting di dalam paket

- 01_database/faiss.index
- 01_database/metadata.sqlite
- Chunk_Corpus_RAG_AMIKOM_V1.jsonl
- chunk_control.jsonl
- chunk_conflict_verifier.jsonl
- chunk_blocked_verifier.jsonl
- 00_manifest/evaluation_chunk_coverage.csv

10.3 Artefak model E5 (blocker)

```
models/e5/761b726dd34fb83930e26aab4e9ac3899aa1fa78/
├── config.json
├── tokenizer.json
├── tokenizer_config.json
└── onnx/model_int8.onnx
```

Model boleh belum tersedia pada fase awal. Namun Gate Retrieval E5 tidak boleh PASS sebelum model, revision, dan hash terverifikasi.

11. Kontrak Data

11.1 QueryRequest

```
{
  "query": "Bagaimana prosedur cuti kuliah?",
  "session_id": "demo-001",
  "user_context": {"cohort": "2025"},
  "requested_mode": "AUTO"
}
```

11.2 RoutingDecision

```
{
  "intents": ["ADMINISTRATION"],
  "temporal_mode": "CURRENT",
  "agents": ["AdministrationAgent"],
  "subqueries": ["prosedur cuti kuliah"],
  "control_flags": [],
  "response_mode": "ANSWER"
}
```

11.3 Evidence

```
{
  "chunk_id": "CH-ADM-B03-DOC-B03-PROCEDURE-0001",
  "source_id": "B03",
  "title": "Permohonan Cuti",
  "locator": "Bagian Persyaratan",
  "lifecycle": "ACTIVE",
  "score": 0.87,
  "chunk_text": "...",
  "freshness_status": "CURRENT"
}
```

11.4 FinalResponse

```
{
  "request_id": "req-20260727-0001",
}
```

```
"mode": "ANSWER",
"answer": "...",
"citations": [{"source_id": "B03", "locator": "Bagian Persyaratan"}],
"freshness_notice": null,
"handoff": null,
"retrieval_backend": "E5_FAISS",
"system_readiness": "PRODUCTION_CANDIDATE",
"verification": {"status": "PASS", "checks": []},
"latency_ms": 842
}
```

12. API Minimum

Method	Endpoint	Fungsi
POST	/api/v1/query	Menjalankan pipeline pertanyaan.
GET	/api/v1/health	Cek proses, database, model, dan LLM client.
GET	/api/v1/readiness	Menyatakan DEGRADED atau READY berdasarkan gate.
GET	/api/v1/sources/{source_id}	Metadata sumber untuk traceability tanpa data sensitif.
POST	/api/v1/evaluation/run	Internal/dev only; menjalankan regression set.

13. Struktur Repository

```
multi-agent-rag-amikom/
├── PRD.md
├── AGENTS.md
├── app/
│   ├── main.py
│   ├── api/
│   ├── config/
│   ├── data/
│   ├── retrieval/
│   ├── controls/
│   ├── agents/
│   ├── coordinator/
│   ├── verifier/
│   ├── generator/
│   └── observability/
├── data/immutable/
├── models/e5/
├── evaluation/
├── tests/
├── scripts/
├── var/logs/
├── var/results/
├── .env.example
├── pyproject.toml
└── README.md
```

14. Environment Variables

```
APP_ENV=development
DATA_ROOT=./data/immutable
FAISS_INDEX_PATH=./data/immutable/vector_db/01_database/faiss.index
METADATA_DB_PATH=./data/immutable/vector_db/01_database/metadata.sqlite
```



```

CHUNK_CORPUS_PATH=./data/immutable/chunk/Chunk_Corpus_RAG_AMIKOM_V1.jsonl
CONTROL_REGISTRY_PATH=./data/immutable/chunk/chunk_control.jsonl
CONFLICT_REGISTRY_PATH=./data/immutable/chunk/chunk_conflict_verifier.jsonl
BLOCKED_REGISTRY_PATH=./data/immutable/chunk/chunk_blocked_verifier.jsonl
E5_MODEL_DIR=./models/e5/761b726dd34fb83930e26aab4e9ac3899aa1fa78
RETRIEVAL_BACKEND=auto
BM25_FALLBACK_ENABLED=true
LLM_PROVIDER=replace_me
LLM_MODEL=replace_me
LLM_API_KEY=
LOG_LEVEL=INFO

```

15. Rencana Implementasi untuk Antigravity

Fase 0 - Intake dan Preflight

Tugas	Output	Gate
Baca PRD, inventaris input, verifikasi hash, buat implementation_plan.md, progress.md, decision_log.md.	Workspace dan laporan file hilang; mode awal DEGRADED/READY.	Data immutable tidak ditulis; database/corpus dapat dibaca.

Fase 1 - Scaffold dan Configuration

Tugas	Output	Gate
Buat repository, dependency, settings, .env.example, logging, error model, typed schemas.	Aplikasi boot, /health, unit test dasar.	Lint dan test PASS; tidak ada secret/path absolut.

Fase 2 - Data Layer

Tugas	Output	Gate
FAISS/SQLite loader read-only, lookup, candidate filter, fetch records, health dan hash verification.	VectorStore, MetadataStore, integration tests.	306 record, dimensi 384, current 0 archive, historical hanya archive.

Fase 3 - Control Registry dan Verifier Dasar

Tugas	Output	Gate
Muat control/conflict/blocked; PII, scope, lifecycle, freshness, CF001/CF002/G01/G02/G04/MR-A11.	ControlRegistry, PrecheckResult, unit tests.	Control regression 36/36; archive leakage 0; fakta sintetis 0.

Fase 4 - Retrieval Abstraction

Tugas	Output	Gate
Interface QueryEncoder/Retriever; BM25 fallback; E5 adapter; retrieval per namespace dan merge.	Backend configurable; tanpa hardcoded evaluation ID.	Fallback DEGRADED; E5 gate BLOCKED jika model tidak ada.

Fase 5 - Retrieval E5 Recovery

Tugas	Output	Gate
Verifikasi model, encode query, pooling, L2, FAISS candidate search, k=1/3/5/10.	Query vectors, metrik, top-k baru, error analysis.	Q02/Q03/Q17 PASS; Retrieval Gate PASS.

Fase 6 - Specialist Agents

Tugas	Output	Gate
Base interface dan tiga agent; task + evidence -> AgentResult.	Agent unit tests dan fixtures.	Agent tidak keluar namespace dan tidak membuat fakta.

Fase 7 - Coordinator

Tugas	Output	Gate
Intent router, temporal classifier, decomposition, quota, merge/dedup.	Multi-intent pipeline.	Kasus EV-C01/EV-C05/EV-C06 diuji ulang.

Fase 8 - Generator, Citation, Final Verifier

Tugas	Output	Gate
Prompt dinamis, LLM client provider-agnostic, citation formatter, claim checks.	Jawaban dinamis dan fail-safe.	Unsupported claim/citation mismatch/PII violation = 0.

Fase 9 - API dan UI Demo

Tugas	Output	Gate
FastAPI, chat UI, source panel, freshness, handoff, metrics.	Demo lokal.	End-to-end test PASS; log aman.

Fase 10 - Evaluation dan Packaging

Tugas	Output	Gate
36 regression + held-out, baseline vs multi-agent, README, report, setup, hash.	Paket UAS final.	Retrieval/Baseline RAG PASS dan human review selesai.

16. Pengujian

16.1 Unit tests wajib

- Settings/path validation.
- SQLite filter current/historical/dynamic.
- Control priority dan short-circuit.
- Query encoder validation.
- Retriever candidate-only ranking.
- Evidence merge/dedup.

- Citation support.
- PII redaction/refusal.

16.2 Integration tests wajib

- Academic tunggal.
- Schedule current dan expired dynamic.
- Schedule historical.
- Administration procedure.
- Multi-intent academic + administration.
- Mixed archive + administration.
- CF002 escalation.
- G02 abstain/handoff.
- Out-of-scope dan PII refusal.

16.3 Target fungsi minimum

- Control decision accuracy 100% pada regression set.
- Archive leakage 0.
- Citation mismatch 0.
- PII violation 0.
- Synthetic blocker/conflict fact 0.
- Semua 36 evaluasi selesai dan traceable.
- Hit@k/MRR ditetapkan setelah E5 berhasil, bukan dari BM25.

17. Risiko dan Mitigasi

Risiko	Dampak	Mitigasi
Model E5 tidak tersedia	Vector query tidak berjalan	Interface encoder + BM25 dev fallback; final gate tetap BLOCKED.
Namespace besar mendominasi	Evidence domain kecil hilang	Retrieval per namespace + kuota + round-robin merge.
Multi-intent tidak terurai	Retrieval miss	Coordinator decomposition dan per-subquery k.
Dynamic source expired	Jawaban current usang	TTL check + LIVE_CHECK_OR_ABSTAIN.
LLM mengarang	Hallucination	Evidence-only prompt + deterministic verifier.
PII masuk log	Risiko privasi	Redaction, denylist, structured safe logging.
Path tidak portabel	Gagal di komputer lain	Env/config relatif; tanpa path hardcoded.
Gold leakage	Evaluasi tidak valid	Gold hanya untuk scoring, bukan runtime.

18. Definition of Done

1. Semua modul dan API berjalan dari repository bersih.
2. Immutable input lolos hash dan tidak berubah.
3. Query E5 dan FAISS retrieval benar-benar dijalankan.
4. Retrieval Gate dan Baseline RAG Gate PASS.
5. Academic, Schedule, Administration, Coordinator, dan Verifier terintegrasi.

6. 30 CORE + 6 SUPPLEMENTARY + held-out cases selesai.
7. Archive leakage, citation mismatch, PII violation, dan synthetic blocker fact bernilai 0.
8. README, setup, tests, report, dan demo tersedia.
9. Tidak ada jawaban atau grade hardcoded berdasarkan evaluation_id.
10. Human review tim menyetujui paket final.

19. Instruksi Eksekusi Antigravity

1. Baca seluruh PRD dan file status sebelum mengubah kode.
2. Buat implementation_plan.md yang memetakan requirement ID ke task dan file.
3. Kerjakan satu fase pada satu waktu.
4. Setelah setiap fase, jalankan lint/test dan tulis hasil ke progress.md.
5. Buat artefak verifikasi: daftar file berubah, perintah test, hasil test, dan keputusan gate.
6. Berhenti jika gate gagal; jangan menandai fase berikutnya selesai.
7. Jangan memodifikasi data/immutable/.
8. Jangan menggunakan hasil BM25 sebagai top-k final E5.
9. Jangan hardcode jawaban, grade, routing, atau gold chunk untuk evaluation ID.
10. Saat model E5 belum ada, lanjutkan fase independen dengan status DEGRADED; jangan memalsukan query vector.
11. Sebelum mulai coding, eksekusi Fase 0 lalu Fase 1 dan berhenti untuk melaporkan gate awal.

19.1 Prompt kickoff

Baca PRD.md sebagai sumber kebutuhan utama dan Roadmap_Implementasi_Multi_Agent_RAG_AMIKOM sebagai penjelasan pendukung.

Kerjakan Fase 0 dan Fase 1 saja:

1. verifikasi seluruh input immutable dan hash yang tersedia;
2. buat implementation_plan.md, progress.md, decision_log.md, dan input_inventory.json;
3. buat scaffold repository, settings berbasis environment, typed schemas, logging, health endpoint, lint, dan unit test awal;
4. jangan memodifikasi corpus/database;
5. jangan menjalankan atau memalsukan E5 retrieval;
6. hentikan setelah Gate Fase 1 dan laporkan file yang dibuat, test yang dijalankan, hasil gate, blocker, dan perintah fase berikutnya.

20. Checklist Input Sebelum Eksekusi

- ☐ PRD ini disimpan sebagai PRD.md di root repository.
- ☐ Roadmap tersedia.
- ☐ Vector database ZIP tersedia dan dapat diekstrak.
- ☐ faiss.index dan metadata.sqlite tersedia.
- ☐ Chunk corpus dan control registries tersedia.
- ☐ Evaluation dataset 30 CORE + 6 SUPPLEMENTARY tersedia.
- ☐ Hash input dicatat.
- ☐ Model E5 tersedia atau blocker dicatat.
- ☐ .env tidak berisi credential pada commit.
- ☐ Antigravity diarahkan memulai Fase 0 dan Fase 1 saja.