

ROADMAP IMPLEMENTASI MULTI-AGENT RAG AMIKOM

**Prototipe Sistem Layanan Akademik Terpadu Mahasiswa S1 Informatika
Universitas AMIKOM Yogyakarta**

*Panduan step by step dari status Baseline RAG CONDITIONAL_PASS
menuju implementasi kode, pengujian, dan demo sistem*

Versi 1.0 - 27 Juli 2026

Dokumen ini disusun untuk tim UAS Proyek Data Mining

Kendali Dokumen

Elemen	Keterangan
Nama dokumen	Roadmap Implementasi Multi-Agent RAG AMIKOM
Status scope	FROZEN
Titik awal	Vector Database Gate PASS; Baseline Retrieval Gate CONDITIONAL_PASS
Titik akhir yang dituju	Multi-Agent Implementation Gate PASS dan siap demo UAS
Pengguna dokumen	Anggota tim pengembang, reviewer, dan dosen penguji
Prinsip utama	Evidence-first, deterministic guardrail, lifecycle-aware, traceable, no synthetic facts

Keputusan utama

Tim boleh mulai membuat struktur project, API, data layer, control layer, dan agent skeleton sekarang. Akan tetapi, sistem belum boleh dinyatakan final atau Ready for Multi-Agent sebelum retrieval berbasis query encoder E5 resmi dijalankan ulang dan kedua gate baseline berubah menjadi PASS.

Daftar Isi

1. Ringkasan Eksekutif
2. Kondisi Proyek Saat Ini
3. Sasaran Arsitektur Multi-Agent
4. Prinsip Implementasi
5. Roadmap Step by Step
6. Struktur Repository dan Modul
7. Kontrak Data Antar-Komponen
8. Alur Eksekusi Pertanyaan
9. Strategi Pengujian dan Evaluasi
10. Pembagian Tugas Tim dan Estimasi Waktu
11. Gate dan Kriteria Penerimaan
12. Risiko dan Mitigasi
13. Keputusan Kesiapan Implementasi
- Lampiran A. File Input Patokan
- Lampiran B. Artefak Model E5
- Lampiran C. Kontrak Prompt Agent

1. Ringkasan Eksekutif

Proyek telah memiliki rantai artefak yang cukup matang: Raw Corpus, Clean Corpus, Chunk Corpus, embedding dokumen, serta vector database FAISS dan metadata SQLite. Tahap Vector Database dan Indexing telah lulus dengan 306 vector berdimensi 384. Lapisan control, filter metadata, pemisahan archive, freshness, conflict, blocker, dan PII juga telah diuji dan dapat digunakan sebagai dasar implementasi.

Kendala utama berada pada tahap Baseline RAG dan Retrieval Testing. Query encoder Xenova/multilingual-e5-small tidak berhasil dijalankan pada lingkungan Claude karena model tidak tersedia dan akses repositori diblokir. Proses kemudian menggunakan BM25 sebagai fallback. Oleh sebab itu, hasil top-k dan metrik retrieval saat ini hanya sah sebagai pembandingan leksikal, bukan sebagai bukti bahwa FAISS dengan E5 telah bekerja pada pertanyaan pengguna.

Roadmap ini memakai strategi paralel yang aman. Pembuatan kode Multi-Agent dapat dimulai pada bagian yang tidak bergantung pada encoder, seperti project scaffold, database loader, control registry, deterministic verifier, API contract, agent interface, logging, dan pengujian unit. Sementara itu, jalur retrieval E5 ditempatkan sebagai gate wajib sebelum integrasi final dan evaluasi multi-agent.

Area	Status saat ini	Keputusan
Corpus dan metadata	Lengkap dan terstruktur	Gunakan tanpa rekonstruksi ulang
Embedding dokumen	306 x 384, Gate PASS	Gunakan apa adanya
FAISS + SQLite	Gate PASS dan persisten	Gunakan sebagai data layer
Control / conflict / blocker	Terverifikasi	Refaktor menjadi modul deterministik
Query encoder E5	Belum tersedia pada paket baseline	Wajib dipulihkan sebelum gate final
BM25 fallback	Berjalan dan terdokumentasi	Simpan hanya sebagai fallback/pembandingan
Baseline top-k=5	Berlaku untuk BM25	Jangan jadikan nilai final E5
Multi-Agent final	Belum diimplementasikan	Bangun bertahap setelah fondasi siap

2. Kondisi Proyek Saat Ini

2.1 Status gate

Tahap	Status	Makna
Scope Freeze	FROZEN	Agent, domain, cohort, dan layanan tidak boleh diperluas tanpa change control.
Clean Corpus Gate	PASS	Dokumen dapat digunakan sebagai sumber pengetahuan.
Chunk Corpus Gate	PASS	Chunk dan metadata siap untuk embedding.
Embedding Gate	PASS	306 embedding dokumen telah dibuat.
Vector Database Gate	PASS	FAISS + SQLite dapat dibuka kembali dan memiliki 306 record.
Retrieval Gate	CONDITIONAL_PASS	Filter dan control valid, tetapi query vector E5 belum dijalankan.
Baseline RAG Gate	CONDITIONAL_PASS	Jawaban baseline tersedia, tetapi retrieval dasarnya masih BM25.
Ready for Multi-Agent	NO	Belum boleh dinyatakan final.

2.2 Komponen yang dapat dipakai langsung

- FAISS IndexIDMap2(IndexFlatIP) dan metadata SQLite sebagai penyimpanan utama.
- Relasi vector_index, vector_id, chunk_id, chunk_text, source_id, locator, lifecycle, dan namespace.
- Filter current, historical, active_dynamic, archive, serta pemisahan agent namespace.
- Control registry INT01-INT07, G01, G02, CF001, CF002, dan MR-A11-RELATIONS.
- Aturan response mode: ANSWER, ASK_CONTEXT, ABSTAIN, ESCALATE, HANDOFF, REFUSE, dan LIVE_CHECK_OR_ABSTAIN.

- Skema evaluasi 30 CORE dan 6 SUPPLEMENTARY serta mapping evaluation-to-chunk.

2.3 Komponen yang tidak boleh dianggap final


- Metrik Hit@k, Recall@k, Precision@k, MRR, dan top-k=5 dari backend BM25.
- encoder.py yang hanya melempar error QUERY_EMBEDDING_BLOCKED.
- retriever.py yang belum melakukan vector search terhadap query pengguna.
- gen_answers.py yang berisi jawaban statis untuk ID evaluasi.
- evaluate.py yang memiliki grade dan error khusus 36 kasus.
- Path absolut /home/claude/work yang tidak portabel.

Batas implementasi saat ini

Kode fondasi dapat dibuat dan diuji. Integrasi final, penetapan top-k, klaim performa retrieval, dan status Ready for Multi-Agent harus menunggu query encoder E5 tersedia dan retrieval recovery selesai.

3. Sasaran Arsitektur Multi-Agent

Arsitektur target memakai satu Coordinator Agent, tiga Specialist Agent, dan satu Verifier/Guardrail deterministik. Specialist Agent bertugas memperoleh evidence dan menyusun draft jawaban pada domain masing-masing. Coordinator hanya mengatur alur, tidak menciptakan fakta. Verifier melakukan pemeriksaan akhir terhadap scope, lifecycle, freshness, konflik, PII, dan dukungan sitasi.



Gambar 1. Arsitektur target Multi-Agent RAG AMIKOM

3.1 Coordinator Agent

- Mendeteksi satu atau lebih intent pada pertanyaan.
- Menentukan agent yang dipanggil dan mode current, historical, atau mixed.
- Memecah pertanyaan multi-intent menjadi sub-query yang dapat dieksekusi terpisah.
- Menentukan kuota retrieval per agent/namespace, lalu menggabungkan hasil secara terkendali.
- Tidak menulis fakta akademik sendiri dan tidak boleh mengabaikan keputusan guardrail.

3.2 Academic Agent

Cakupan: Kurikulum 2025, daftar mata kuliah, kode, SKS, konsentrasi, penyetaraan kurikulum, ketentuan akademik, dan syarat kelulusan yang tidak berada dalam konflik terbuka. Namespace utama adalah active_academic. Untuk CF002, agent harus menyerahkan keputusan kepada Verifier dan menghasilkan escalation, bukan memilih salah satu klaim.

3.3 Schedule Agent

Cakupan: kalender akademik, agenda semester, KRS, perubahan KRS, perkuliahan, ujian, cuti terkait jadwal, dan pertanyaan historis. Agent harus membedakan `active_schedule`, `active_dynamic_schedule`, dan `archive_schedule`. Hasil `ACTIVE_DYNAMIC` harus melewati pemeriksaan TTL dan live check. G02 tidak boleh menghasilkan tanggal sintetis.

3.4 Administration Agent

Cakupan: KRS manual, cuti, SKAK, legalisir, KTM, perubahan data PDDIKTI, serta prosedur administrasi lain yang telah dibekukan dalam scope. Agent menjelaskan prosedur umum, tetapi tidak memproses transaksi personal, status permohonan, atau dokumen identitas aktual.

3.5 Verifier/Guardrail Deterministik

Verifier bukan LLM bebas. Modul ini berupa aturan deterministik yang dapat diuji. Ia memeriksa PII, out-of-scope, conflict, blocker, lifecycle, current-vs-archive, freshness, source authority, citation support, dan konsistensi response mode. Jawaban tidak boleh keluar jika evidence atau control decision tidak memenuhi syarat.

4. Prinsip Implementasi

Prinsip	Penerapan
Evidence-first	Setiap jawaban faktual harus memiliki satu atau lebih chunk yang jelas, <code>source_id</code> , <code>locator</code> , dan <code>lifecycle</code> .
Control-before-retrieval	Privacy, scope, conflict, blocker, dan route temporal diperiksa sebelum vector search.
Filter-before-ranking	Candidate <code>vector_index</code> ditentukan melalui SQLite sebelum similarity ranking; dilarang global top-k lalu membuang hasil.
Lifecycle-aware	<code>ACTIVE</code> , <code>ACTIVE_DYNAMIC</code> , dan <code>ARCHIVE</code> memiliki aturan penggunaan berbeda.
No synthetic fact	Coordinator, specialist, dan generator tidak boleh menciptakan tanggal, ambang nilai, kode mata kuliah, atau persyaratan yang tidak ada pada sumber.
Traceable	Request, routing, chunk, score, source, citation, response mode, dan verifier decision harus disimpan pada audit log.
Offline-first	Model query encoder dipaketkan lokal dengan revision dan SHA-256 tetap agar tidak bergantung pada akses internet.
Fail closed	Jika hash, model, database, atau control registry tidak valid, sistem berhenti atau abstain, bukan menebak.

5. Roadmap Step by Step

Urutan berikut dirancang agar tim dapat mulai coding sekarang tanpa merusak gate proyek. Setiap fase menghasilkan artefak yang dapat disimpan dan dipakai kembali. Jangan melompat ke fase berikutnya jika gate fase sebelumnya gagal.

Fase 0 - Bekukan Input dan Siapkan Repository

Tujuan fase ini adalah memastikan kedua anggota tim bekerja pada artefak, konfigurasi, dan status yang sama.

1. Buat repository Git baru dan tag awal, misalnya `multi-agent-rag-amikom-v0.1`.
2. Salin file input ke folder `data/immutable` dan ubah permission menjadi `read-only`.
3. Catat SHA-256 seluruh input pada `data/manifest/input_hashes.json`.
4. Buat `.env.example` tanpa credential aktual.
5. Tentukan satu versi Python, FAISS, SQLite, ONNX Runtime, dan library web.
6. Dokumentasikan blocker `QUERY_ENCODER_UNAVAILABLE` dan larangan memakai top-k BM25 sebagai final.

Output	Kriteria selesai
Repository dan branch strategy	Kedua anggota dapat clone dan menjalankan health check.
Immutable input manifest	Hash semua file sesuai dengan paket final sebelumnya.
Environment lock	requirements.txt/pyproject.toml dan versi runtime tercatat.

Gate F0

PASS apabila repository dapat dijalankan pada dua perangkat, seluruh hash input cocok, dan tidak ada artefak lama yang dimodifikasi.

Fase 1 - Bangun Project Scaffold dan Data Layer

Fase ini tidak membutuhkan query encoder. Fokus pada kemampuan sistem membuka FAISS dan SQLite, membaca control registry, serta menyediakan interface yang stabil.

7. Buat package config, data, retrieval, controls, agents, coordinator, verifier, generator, api, evaluation, dan tests.
8. Implementasikan Settings yang membaca path melalui environment variable, bukan path absolut.
9. Implementasikan VectorStore yang membuka faiss.index dan metadata.sqlite dalam mode read-only.
10. Implementasikan fungsi lookup vector_id/chunk_id, candidate_indexes(filter), fetch_records(indexes), dan health_check().
11. Muat chunk_control.jsonl, chunk_conflict_verifier.jsonl, dan chunk_blocked_verifier.jsonl ke ControlRegistry.
12. Buat Pydantic/dataclass untuk QueryRequest, RoutingDecision, Evidence, AgentResult, VerificationResult, dan FinalResponse.

```
class VectorStore:
    def health_check(self) -> StoreHealth: ...
    def candidate_indexes(self, filter: RetrievalFilter) -> list[int]: ...
    def fetch_records(self, indexes: list[int]) -> list[ChunkRecord]: ...
    def search_candidates(self, query_vector, indexes, k): ...
```

Gate F1

PASS apabila database 306 x 384 terbuka, metadata 306 record terbaca, current filter menghasilkan 281 kandidat, archive menghasilkan 25, dan control registry memuat 10 CONTROL + 2 CONFLICT + 1 BLOCKED.

Fase 2 - Pulihkan Query Encoder E5 dan Vector Retrieval

Fase ini adalah blocker teknis utama. Tim boleh mengerjakan fase lain secara paralel, tetapi integrasi final harus menunggu fase ini lulus.

13. Sediakan config.json, tokenizer.json, tokenizer_config.json, dan onnx/model_int8.onnx secara offline.
14. Verifikasi revision 761b726dd34fb83930e26aab4e9ac3899aa1fa78 dan SHA-256 setiap file.
15. Implementasikan encoder lokal: prefix query, tokenization, ONNX inference, mean pooling, L2 normalization, float32, dimensi 384.
16. Buat tes untuk query kosong, query normal, query panjang, karakter Indonesia, NaN/Infinity, zero vector, dan norm.
17. Buktikan parity dengan model dokumen melalui sanity test dan, bila memungkinkan, sample passage reconstruction.
18. Implementasikan FAISS inner-product hanya pada kandidat yang lolos filter SQLite.
19. Jalankan ulang 30 CORE + 6 SUPPLEMENTARY pada k=1,3,5,10 dan tetapkan ulang top-k.

```
formatted = "query: " + user_query.strip()
tokens = tokenizer(formatted)
hidden = onnx_model(tokens)
vector = mean_pool(hidden, attention_mask)
vector = l2_normalize(vector).astype("float32")
assert vector.shape == (384,)
```

Gate F2 - Retrieval Recovery Gate

PASS apabila 36 query menghasilkan vector 384 valid, FAISS search benar-benar dijalankan, Q02/Q03/Q17 menjadi PASS, top-k ditetapkan ulang, dan Retrieval Gate serta Baseline RAG Gate berubah menjadi PASS.

Fase 3 - Implementasikan Control Layer dan Verifier

Control dan verifier harus dibuat sebelum specialist agent agar setiap agent menggunakan aturan yang sama.

20. Implementasikan PII detector untuk NIM, nomor identitas, dokumen personal, credential, nilai, dan data transaksi.
21. Implementasikan scope classifier untuk memisahkan layanan in-scope dan out-of-scope.
22. Implementasikan aturan CF002, G01, G02, G04, CF001, dan MR-A11-RELATIONS.
23. Implementasikan lifecycle policy: current tidak boleh memakai archive; historical hanya memakai archive; dynamic memerlukan TTL.
24. Implementasikan CitationVerifier yang memastikan setiap klaim faktual didukung evidence.
25. Implementasikan response mode resolver dan handoff target.
26. Tulis unit test untuk setiap control secara terpisah dan kombinasi prioritasnya.

Kondisi	Keputusan wajib
PII atau dokumen identitas aktual	REFUSE atau ESCALATE; jangan simpan payload sensitif.
G02 agenda belum tersedia	ABSTAIN/HANDOFF ke kanal resmi.
CF002 ambang IPK konflik	ESCALATE; tampilkan bahwa sumber berbeda tanpa memilih nilai tunggal.
A03 snapshot kedaluwarsa	LIVE_CHECK_OR_ABSTAIN.
Pertanyaan current tetapi evidence archive	Tolak evidence dan ulang retrieval current.
A11 relasi panah ambigu	ASK_CONTEXT/ESCALATE; jangan menyimpulkan prasyarat.

Gate F3

PASS apabila seluruh control CORE dan SUPPLEMENTARY menghasilkan response mode yang benar, archive leakage=0, blocker tidak menjadi fakta, dan verifier menolak jawaban tanpa evidence.

Fase 4 - Implementasikan Specialist Agents

Gunakan satu interface yang sama agar Coordinator dapat memanggil semua agent tanpa mengetahui detail internalnya.

```
class SpecialistAgent(Protocol):
    name: str
    namespaces: list[str]
    async def run(self, task: AgentTask) -> AgentResult: ...
```

Fase 4A - Academic Agent

- Route hanya ke active_academic, kecuali control menentukan escalation.
- Gunakan retrieval per source atau diversifikasi agar A10/A12 tidak tenggelam oleh dokumen naratif.
- Gunakan source_priority sebagai tie-break jika skor berdekatan.
- Kembalikan evidence terurut, draft jawaban, citation, unresolved flags, dan confidence.

Fase 4B - Schedule Agent

- Klasifikasikan current, historical, atau mixed sebelum retrieval.
- Pisahkan kuota archive dan current pada pertanyaan multi-intent.
- Evaluasi TTL seluruh ACTIVE_DYNAMIC sebelum evidence dikirim ke generator.
- Gunakan abstain/handoff jika informasi current tidak dapat diverifikasi.

Fase 4C - Administration Agent

- Route ke active_administration dan bagian prosedural A01 bila relevan.

- Untuk prosedur multi-chunk, gunakan source diversification atau adaptive k.
- Jelaskan persyaratan dan langkah umum tanpa meminta dokumen personal di chat.
- Tandai authentication_required, handoff_required, dan official_channel.

Gate F4

PASS apabila setiap agent berhasil menjawab test domain tunggal dengan evidence benar, citation valid, response mode benar, dan tidak mengakses namespace yang tidak diizinkan.

Fase 5 - Implementasikan Coordinator Agent

Coordinator menangani pertanyaan multi-intent yang menjadi sumber beberapa error pada baseline BM25. Ia harus melakukan dekomposisi dan retrieval terpisah, bukan menggabungkan seluruh namespace dalam satu ranking.

27. Normalisasi pertanyaan dan identifikasi bahasa.
28. Klasifikasikan intent: academic, schedule, administration, atau kombinasi.
29. Deteksi temporal: current, historical, mixed, atau tidak relevan.
30. Pisahkan sub-query per intent dan tetapkan agent serta filter masing-masing.
31. Jalankan agent secara serial atau paralel dengan timeout.
32. Gabungkan evidence menggunakan kuota per agent/source dan hapus duplikasi.
33. Teruskan hasil ke Verifier sebelum generator final.

```
query -> control precheck -> intent decomposition
      -> [AcademicTask, ScheduleTask, AdministrationTask]
      -> per-agent filtered retrieval
      -> merge evidence with quotas
      -> draft synthesis
      -> deterministic verification
      -> final response
```

Gate F5

PASS apabila skenario multi-intent EV-C01, EV-C05, dan EV-C06 tidak lagi mengalami dominasi namespace dan setiap sub-intent memperoleh evidence atau status abstain yang tepat.

Fase 6 - Context Assembly, Generator, dan Citation

Generator boleh memakai satu LLM untuk UAS, tetapi prompt dan inputnya harus dibangun dinamis. Jangan menggunakan jawaban hardcoded berdasarkan evaluation_id.

34. Context assembler menyusun evidence dalam batas token, mengelompokkan source, dan mempertahankan locator.
35. Prompt generator menyatakan bahwa jawaban hanya boleh berdasarkan evidence.
36. Generator menerima control directive terpisah dari knowledge context.
37. Citation formatter menghasilkan format yang konsisten, misalnya [A10, baris 12] atau [B04, bagian Persyaratan].
38. Verifier membandingkan klaim dengan evidence, lalu dapat ACCEPT, REVISE, ABSTAIN, atau ESCALATE.
39. Jika LLM tidak tersedia, sistem masih dapat menghasilkan template response untuk abstain, handoff, dan procedure summary sederhana.

Gate F6

PASS apabila tidak ada unsupported claim, citation mismatch, archive-for-current, synthetic blocker fact, atau pelanggaran PII pada test set.

Fase 7 - API, UI, dan Observability

Untuk UAS, implementasi minimum dapat berupa backend FastAPI dan antarmuka chat sederhana. Prioritaskan fungsi dan bukti evaluasi, bukan kompleksitas visual.

Endpoint	Fungsi
GET /health	Memeriksa model, FAISS, SQLite, control registry, dan LLM.
POST /v1/query	Memproses satu pertanyaan melalui pipeline Multi-Agent.
GET /v1/sources/{source_id}	Menampilkan metadata sumber dan locator yang aman.
POST /v1/admin/reload	Memuat ulang config/control secara terkontrol; dilindungi untuk demo lokal.
GET /v1/audit/{request_id}	Menampilkan route, evidence, score, citation, dan decision untuk explainability.

- Buat request_id unik untuk setiap pertanyaan.
- Log waktu control, routing, encoding, retrieval, generation, dan verification.
- Jangan menyimpan payload PII mentah.
- UI menampilkan jawaban, citation, status freshness, dan handoff jika ada.

Gate F7

PASS apabila aplikasi dapat dijalankan dari satu perintah, health check hijau, pertanyaan masuk menghasilkan response schema valid, dan audit trail dapat dibuka.

Fase 8 - Pengujian Multi-Agent dan Evaluasi Akhir

40. Jalankan unit test tiap modul dan integration test pipeline penuh.
41. Gunakan 30 CORE + 6 SUPPLEMENTARY sebagai regression set.
42. Tambahkan 10-15 held-out cases yang tidak dipakai untuk menyusun aturan.
43. Bandingkan single-agent baseline vs multi-agent pada metrik yang sama.
44. Uji fault injection: model hilang, SQLite gagal, FAISS hash berubah, TTL expired, LLM timeout, dan evidence kosong.
45. Lakukan human review minimal dua anggota untuk sampel lintas domain.

Gate F8 - Multi-Agent Evaluation Gate

PASS apabila accuracy, effectiveness, efficiency, explainability, dan hallucination memenuhi target yang ditetapkan; control accuracy tetap tinggi; archive leakage dan pelanggaran PII tetap nol; serta seluruh hasil dapat direproduksi.

Fase 9 - Packaging, Dokumentasi, dan Demo UAS


46. Buat Dockerfile atau script setup lokal yang memasang dependency dan menunjuk model offline.
47. Simpan model dan database pada volume read-only untuk demo.
48. Buat README instalasi, arsitektur, API, konfigurasi, dan troubleshooting.
49. Siapkan laporan final yang menjelaskan perbedaan BM25 baseline dan E5 vector retrieval.
50. Siapkan 6-8 skenario demo: academic, schedule current, historical, administration, conflict, blocker, out-of-scope, dan PII.
51. Buat backup paket final beserta SHA-256.

Gate F9 - Demo Readiness

PASS apabila sistem dapat dijalankan dari perangkat lain, seluruh skenario demo berhasil, log/citation terlihat, dan dokumentasi sesuai status nyata tanpa klaim yang belum diuji.

6. Struktur Repository dan Modul

```
multi-agent-rag-amikom/
├── app/
└── main.py
```



Keterangan: data/immutable tidak boleh ditulis ulang oleh aplikasi. Output runtime, log, cache, dan evaluation result ditempatkan di folder terpisah. Model offline memiliki manifest hash sendiri.

7. Kontrak Data Antar-Komponen

7.1 QueryRequest

```

{
  "query": "Bagaimana prosedur cuti kuliah?",
  "session_id": "demo-001",
  "user_context": {"cohort": "2025"},
  "requested_mode": "AUTO"
}

```

7.2 RoutingDecision

```
{
  "intents": ["ADMINISTRATION"],
  "temporal_mode": "CURRENT",
  "agents": ["AdministrationAgent"],
  "subqueries": ["prosedur cuti kuliah"],
  "control_flags": [],
  "response_mode": "ANSWER"
}
```

7.3 Evidence

```
{
  "chunk_id": "CH-ADM-B03-DOC-B03-PROCEDURE-0001",
  "source_id": "B03",
  "title": "Permohonan Cuti",
  "locator": "Bagian Persyaratan",
  "lifecycle": "ACTIVE",
  "score": 0.87,
  "chunk_text": "...",
  "freshness_status": "CURRENT"
}
```

7.4 AgentResult

```
{
  "agent": "AdministrationAgent",
  "status": "SUCCESS",
  "draft_answer": "...",
  "evidence": [...],
  "unresolved_flags": [],
  "handoff": null,
  "confidence": 0.84
}
```

7.5 FinalResponse

```
{
  "request_id": "req-20260727-0001",
  "mode": "ANSWER",
  "answer": "...",
  "citations": [{"source_id": "B03", "locator": "Bagian Persyaratan"}],
  "freshness_notice": null,
  "handoff": null,
  "verification": {"status": "PASS", "checks": [...]},
  "latency_ms": 842
}
```

8. Alur Eksekusi Pertanyaan

No.	Langkah	Output utama
1	API menerima query	Validasi schema, panjang, encoding, dan request_id.
2	Pre-control	PII, out-of-scope, conflict, blocker, dan route temporal.
3	Coordinator routing	Tentukan intent, agent, sub-query, dan mode current/historical/mixed.
4	Metadata candidate filter	Ambil vector_index yang diizinkan dari SQLite.
5	Query encoding	query: + E5 offline + mean pooling + L2 + vector 384.
6	Per-agent ranking	FAISS inner product pada candidate set dan kuota agent/source.

No.	Langkah	Output utama
7	Context assembly	Gabungkan evidence tanpa duplikasi dan dalam batas token.
8	Agent draft	Specialist menyusun jawaban domain berdasarkan evidence.
9	Coordinator merge	Gabungkan hasil multi-intent tanpa menciptakan fakta.
10	Verifier	Periksa citation, lifecycle, freshness, conflict, PII, dan response mode.
11	Final response	Kirim answer/citation atau abstain/handoff.
12	Audit	Simpan route, chunk, score, latency, dan keputusan secara aman.

8.1 Pseudocode pipeline

```

async def answer(query):
    pre = control_registry.precheck(query)
    if pre.short_circuit:
        return verifier.finalize_control(pre)

    plan = coordinator.plan(query, pre)
    agent_results = []
    for task in plan.tasks:
        candidate_ids = store.candidate_indexes(task.filter)
        qvec = encoder.encode_query(task.subquery)
        evidence = retriever.search(qvec, candidate_ids, task.k)
        agent_results.append(await task.agent.run(task, evidence))

    merged = coordinator.merge(agent_results)
    draft = generator.generate(query, merged.evidence, pre.directive)
    verification = verifier.verify(query, draft, merged.evidence, pre)
    return response_builder.build(draft, verification)

```

9. Strategi Pengujian dan Evaluasi

9.1 Unit test

Modul	Test minimum
VectorStore	Reload, count, dimension, lookup, filter, read-only, hash mismatch.
Encoder	Prefix query, shape 384, dtype, norm, deterministic output, invalid model.
Control	PII, out-of-scope, G01, G02, CF001, CF002, archive/current.
Retriever	Candidate-only ranking, top-k, tie-break, source diversity, empty candidate.
Agents	Namespace restriction, evidence contract, no unsupported draft.
Coordinator	Single intent, multi-intent, decomposition, timeout, partial result.
Verifier	Citation mismatch, unsupported claim, stale dynamic, archive leakage.

9.2 Integration test

- Academic tunggal: SKS, mata kuliah, penyetaraan, kelulusan.
- Schedule current: kalender dinamis dan TTL.
- Schedule historical: archive only.
- Administration: cuti, SKAK, legalisir, KTM, PDDIKTI.
- Multi-intent: gabungan academic + administration atau archive + administration.
- Conflict: CF002 menghasilkan escalation.

- Blocker: G02 menghasilkan abstain/handoff.
- Out-of-scope dan PII menghasilkan refuse/redirect.

9.3 Metrik akhir

Dimensi UAS	Metrik yang disarankan
Accuracy	Response-mode accuracy, factual correctness, source correctness, retrieval Hit@k/MRR.
Effectiveness	Task completion, evidence coverage, citation support, multi-intent completeness.
Efficiency	Latency encoder/retrieval/generator/total, context token, jumlah agent dipanggil.
Explainability	Traceable source_id/locator, route explanation, abstain/handoff reason.
Hallucination	Unsupported claim, citation mismatch, synthetic blocker fact, archive leakage, PII.

9.4 Target minimum yang realistis

Target numerik sebaiknya ditentukan setelah retrieval E5 berhasil. Sebagai batas fungsi yang tidak bergantung pada skor retrieval, gunakan target berikut: control decision accuracy 100% pada regression set, archive leakage 0, PII violation 0, citation mismatch 0, synthetic blocker fact 0, seluruh 36 evaluasi selesai, serta seluruh input dan output memiliki hash yang valid.

10. Pembagian Tugas Tim dan Estimasi Waktu

Contoh pembagian berikut ditujukan untuk tim dua orang dan dapat disesuaikan. Pekerjaan retrieval recovery dan scaffold dapat berlangsung paralel.

Periode	Anggota 1	Anggota 2	Output
Hari 1-2	Repository, config, VectorStore	ControlRegistry, schema, tests awal	Gate F0-F1
Hari 3-4	Offline E5 encoder dan FAISS retrieval	PII/scope/lifecycle/freshness rules	Gate F2-F3
Hari 5-6	Academic + Schedule Agent	Administration Agent + verifier	Gate F4
Hari 7-8	Coordinator dan merge strategy	Generator, citation, API	Gate F5-F7
Hari 9-10	Evaluation runner dan metrics	UI, audit log, held-out tests	Gate F8
Hari 11-12	Packaging dan deployment	Laporan, slide/demo script	Gate F9

Estimasi 12 hari kerja adalah rencana, bukan batas wajib. Apabila artefak model E5 belum tersedia, anggota yang bertugas pada retrieval mengerjakan interface encoder dan fake/stub hanya untuk unit test, sementara status integration test tetap BLOCKED.

11. Gate dan Kriteria Penerimaan

Gate	PASS apabila	Jika gagal
F0 Input	Hash, scope, environment, dan repository konsisten.	Hentikan dan perbaiki input.
F1 Data Layer	FAISS/SQLite/control registry valid dan read-only.	Jangan lanjut ke retrieval.
F2 Retrieval Recovery	Query vector E5 384 valid dan gate baseline PASS.	Multi-agent final tetap NO.
F3 Guardrail	Control mode benar, leakage/PII/synthetic fact nol.	Fail closed atau abstain.
F4 Specialist	Setiap agent patuh namespace dan evidence contract.	Perbaiki agent/domain routing.
F5 Coordinator	Multi-intent terdekomposisi dan merged	Jangan gabungkan namespace global.

Gate	PASS apabila	Jika gagal
	secara adil.	
F6 Generator	Citation valid dan unsupported claim nol.	Revisi prompt/verifier.
F7 Application	API/UI dapat dijalankan dan audit lengkap.	Perbaiki integrasi.
F8 Evaluation	Metrik lengkap dan target minimum terpenuhi.	Tetapkan CONDITIONAL/FAIL.
F9 Demo	Portable, reproducible, dokumentasi dan demo lulus.	Jangan klaim final.

12. Risiko dan Mitigasi

Risiko	Dampak	Mitigasi
Model E5 tidak tersedia	Query vector tidak dapat dibuat.	Bundel model offline, revision pin, SHA-256, recovery prompt.
Model/revision berbeda	Query dan document vector tidak kompatibel.	Fail hash check; jangan memakai latest revision otomatis.
Path absolut	Kode gagal di perangkat teman.	Gunakan .env dan pathlib relatif.
Namespace besar mendominasi	Gold dari agent kecil tenggelam.	Retrieve per agent/namespace lalu merge dengan kuota.
Prosedur multi-chunk	Sebagian langkah hilang.	Adaptive k dan source diversification.
Archive leakage	Jawaban current memakai data lama.	Filter sebelum ranking dan verifier lifecycle.
Dynamic stale	Tanggal kedaluwarsa dianggap current.	TTL check dan live-check-or-abstain.
LLM hallucination	Klaim tidak didukung evidence.	Prompt evidence-only, citation verifier, fail closed.
PII tersimpan	Pelanggaran privasi.	Redaction/log minimization/refuse document upload.
Token/resource habis	Proses terhenti di tengah.	Checkpoint per fase dan deliverable persisten.

13. Keputusan Kesiapan Implementasi

Aktivitas	Boleh sekarang?	Catatan
Membuat repository dan struktur kode	YA	Tidak bergantung encoder.
Memakai FAISS dan SQLite yang ada	YA	Buka read-only dan verifikasi hash.
Membangun control dan verifier	YA	Pertahankan registry dan prioritas aturan.
Membangun agent skeleton dan API	YA	Gunakan interface stabil.
Memakai BM25 sebagai fallback	YA, terbatas	Jangan jadikan benchmark final.
Menetapkan top-k=5 final	TIDAK	Nilai tersebut berasal dari BM25.
Menyatakan vector retrieval sudah diuji	TIDAK	Query encoder belum dijalankan pada paket baseline.
Menetapkan Ready for Multi-Agent final	TIDAK	Tunggu Gate F2 dan F8 PASS.
Melakukan demo skeleton/internal	YA	Tampilkan status blocker secara jujur.

Kesimpulan roadmap

Teman Anda dapat segera memulai eksekusi kode menggunakan database, metadata, control registry, dan kontrak arsitektur dalam dokumen ini. Urutan aman adalah membangun scaffold dan guardrail terlebih dahulu, memulihkan query encoder E5, lalu mengintegrasikan specialist agents, coordinator, generator, verifier, API, dan evaluasi akhir. Jangan melewati Retrieval Recovery Gate.

Lampiran A. File Input Patokan

File	Peran
Vector_Database_RAG_AMIKOM_V1.zip	faiss.index, metadata.sqlite, indexed_records, checkpoint, QA.
Vector_Database_Config_RAG_AMIKOM_V1.json	Konfigurasi database, dimensi, metric, namespace, model sumber.
final_package_validation.json	Hash dan validasi integritas paket database.
Embedding_Config_RAG_AMIKOM_V1.json	Model/revision/tokenizer/pooling/normalisasi/dimensi.
Chunk_Corpus_RAG_AMIKOM_V1.zip	Chunk utama, control, conflict, blocker, evaluation coverage.
Inventaris_Sumber_RAG_AMIKOM_V2_Pasca_Scope_Freeze.xlsx	Sheet 07_Evaluation_Dataset: 30 CORE + 6 SUPPLEMENTARY.
Baseline_RAG_Retrieval_Test_RAG_AMIKOM_V1.zip	Kode control/store dan baseline BM25 sebagai pembanding.
Retrieval_Recovery_Prompt.md	Langkah pemulihan retrieval E5.
Status_Tahap_Baseline_RAG_Retrieval_Testing.md	Status terakhir dan blocker.

Lampiran B. Artefak Model E5

Folder model offline harus menggunakan repositori Xenova/multilingual-e5-small pada revision 761b726dd34fb83930e26aab4e9ac3899aa1fa78. Empat artefak minimum:

```
models/e5/761b726dd34fb83930e26aab4e9ac3899aa1fa78/
├── config.json
├── tokenizer.json
├── tokenizer_config.json
├── onnx/
│   └── model_int8.onnx
```

Artefak	SHA-256
config.json	cb99455288675345e1a4f411438d5d0adbba5fbd3a67ea4fb03c015433b996c1
tokenizer.json	0b44a9d7b51c3c62626640cda0e2c2f70fdacdc25bbbd68038369d14ebdf4c39
tokenizer_config.json	a1d6bc8734a6f635dc158508bef000f8e2e5a759c7d92f984b2c86e5ff53425b
onnx/model_int8.onnx	4d24e2bc01a447951524466ef533e52944bf48509e6552810bcee1a2711cb02c

Apabila satu hash berbeda, proses harus berhenti. Jangan mengganti model dengan revision terbaru tanpa membuat embedding dokumen ulang dan mengulang seluruh gate terkait.

Lampiran C. Kontrak Prompt Agent

C.1 Kontrak umum specialist agent

Anda adalah Specialist Agent pada domain yang ditentukan.
Gunakan hanya EVIDENCE yang diberikan.
Jangan membuat fakta, tanggal, kode, angka, atau persyaratan baru.
Jika evidence tidak cukup, nyatakan tidak ditemukan dan gunakan response mode yang ditetapkan.
Pertahankan source_id dan locator untuk setiap klaim.
Jangan meminta atau mengulang PII.
Jangan menggunakan ARCHIVE untuk pertanyaan current.
Keluaran harus mengikuti schema AgentResult.

C.2 Kontrak Coordinator

Coordinator mengklasifikasikan dan memecah pertanyaan.
Coordinator tidak menciptakan fakta dan tidak menulis jawaban akademik tanpa hasil agent.
Untuk multi-intent, buat sub-query terpisah dan alokasikan kuota retrieval per agent.
Gabungkan hasil tanpa menghapus status conflict, freshness, abstain, atau handoff.
Kirim seluruh evidence dan control flags ke Verifier.

C.3 Kontrak Verifier

Periksa response mode, PII, scope, lifecycle, freshness, conflict, blocker, dan citation.
Setiap klaim faktual harus didukung evidence.
Jika citation tidak mendukung klaim, tandai REVISE atau ABSTAIN.
Jika dynamic evidence expired, gunakan LIVE_CHECK_OR_ABSTAIN.
Jika CF002/G02/MR-A11 aktif, jangan mengizinkan jawaban faktual yang dilarang.
Keluaran: PASS, REVISE, ABSTAIN, ESCALATE, HANDOFF, atau REFUSE.

Referensi Artefak Proyek

- Laporan_Baseline_RAG_Retrieval_Test_RAG_AMIKOM_V1.pdf
- README_Baseline_RAG_Retrieval_Test.md
- Retrieval_Config_RAG_AMIKOM_V1.json
- Retrieval_Recovery_Prompt.md
- Status_Tahap_Baseline_RAG_Retrieval_Testing.md
- Laporan_Vector_Database_Indexing_RAG_AMIKOM_V1.pdf
- Embedding_Config_RAG_AMIKOM_V1.json